



ARISTOTLE UNIVERSITY OF THESSALONIKI

ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ

Πολυτεχνική Σχολή

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Τομέας Ηλεκτρονικής και Υπολογιστών

Τεχνικές βαθιάς μάθησης για υλοποίηση προσαρμοστικών πρακτόρων με εφαρμογή στις χρηματοοικονομικές συναλλαγές

Χαράλαμπος Κεμαλίδης

Faculty of Sciences

School of Informatics

Month 2025

*This thesis is submitted in partial fulfilment of the requirements
for the Degree of Informatics*

Copyright © 2025 Χαράλαμπος Κεμαλίδης

Typeset by the author with the Xe_{La}TeX documentation system.

Month 2025.



ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ

Σχολή Θετικών Επιστημών

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης

Τεχνικές βαθιάς μάθησης για υλοποίηση
προσαρμοστικών πρακτόρων με εφαρμογή
στην ρομποτική και στις
χρηματοοικονομικές συναλλαγές

Όνομα Συγγραφέα

Επιβλέπων Καθηγητής:

Σχολή Θετικών Επιστημών
Τμήμα Πληροφορικής

Μήνας Έτος

Περίληψη

Abstract

Ευχαριστίες

Contents

Περίληψη	ii
Abstract	iii
Ευχαριστίες	iv
Contents	v
List of Figures	vii
List of Tables	viii
1. Εισαγωγή	1
1.1. Πλαίσιο & Κίνητρο	1
1.2. Διατύπωση προβλήματος	2
1.3. Στόχος και προτεινόμενη προσέγγιση	3
1.4. Συνεισφορές	4
1.5. Δομή Εργασίας	4
2. Επισκόπηση της Ερευνητικής Περιοχής	5
2.1. Από τα Κλειστά Προσομοιωμένα Περιβάλλοντα στα Ανοιχτά Στοχαστικά Συστήματα	5
2.2. Τεχνητή Νοημοσύνη και Μηχανική Μάθηση στις Αγορές	6
2.3. Βαθιά Μάθηση στις Χρηματοοικονομικές Συναλλαγές	6
2.4. Ενισχυτική Μάθηση και Ακολουθιακή Λήψη Αποφάσεων	7
2.5. Ανάλυση Συναισθήματος και Εναλλακτικά Δεδομένα	7
2.5.1. Οικονομικές Ειδήσεις και Μέσα Κοινωνικής Δικτύωσης	8
2.5.2. Από τα Λεξικά στα Μεγάλα Γλωσσικά Μοντέλα (LLMs)	8
3. Θεωρητικό Υπόβαθρο	10
3.1. Μηχανική Μάθηση	10
3.1.1. Επιβλεπόμενη Μάθηση	11
3.1.2. Μη Επιβλεπόμενη Μάθηση	12
3.1.3. Ενισχυτική Μάθηση	13

3.2. Νευρωνικά Δίκτυα και Βαθιά Μάθηση	13
3.2.1. Μονοεπίπεδα και Πολυεπίπεδα Δίκτυα Πρόσθιας Τροφοδότησης . . .	14
3.2.2. Συναρτήσεις Ενεργοποίησης	15
3.2.3. Συναρτήσεις Σφάλματος / Κόστους	16
3.2.4. Εκπαίδευση Νευρωνικών Δικτύων	17
3.2.5. Αναδρομικά Δίκτυα και Δίκτυα Μακράς Βραχύχρονης Μνήμης (LSTM)	19
3.3. Βαθιά Ενισχυτική Μάθηση	20
3.3.1. Μαρκοβιανές Διαδικασίες Απόφασης (MDP)	21
3.3.2. Εξισώσεις Bellman	22
3.3.3. Μερικώς Παρατηρήσιμη Μαρκοβιανή Διαδικασία Απόφασης (POMDP)	22
3.3.4. Πράκτορες που Λαμβάνουν Υπόψη τη Μερική Παρατηρησιμότητα . .	23
3.3.5. Περιορισμένες Μαρκοβιανές Διαδικασίες Απόφασης (CMDP)	24
3.3.6. Μέθοδοι Βαθιάς Ενισχυτικής Μάθησης	24
3.3.7. Αλγόριθμος Proximal Policy Optimization (PPO)	26
3.4. Μεγάλα Γλωσσικά Μοντέλα και Ανάλυση Συναισθήματος	27
3.4.1. Επεξεργασία Φυσικής Γλώσσας και η Αρχιτεκτονική Transformer . .	27
3.4.2. Μεγάλα Γλωσσικά Μοντέλα (LLMs)	28
3.4.3. Ανάλυση Συναισθήματος	29
3.4.4. Ανάλυση Συναισθήματος με LLM	29
3.4.5. Αποδοτική Μικρο-προσαρμογή: Low-Rank Adaptation (LoRA) . . .	30
3.5. Χρηματοοικονομικές Συναλλαγές	30
3.5.1. Βασικές Έννοιες στις Χρηματοοικονομικές Αγορές	30
3.5.2. Χρηματοοικονομικά Δεδομένα, Κεριά και Θέσεις	32
3.5.3. Κέρδος και Ζημία (Profit and Loss)	32
3.5.4. Ενεργό Κέρδος (Alpha) και Μέτρα Προσαρμοσμένα στον Κίνδυνο .	33
3.5.5. Τεχνητή Νοημοσύνη στις Συναλλαγές	34
4. Προτεινόμενη Μέθοδος	36
5. Πειράματα - Αποτελέσματα	37
6. Συμπεράσματα	38
References	39
A'.Appendix	44

List of Figures

3.1. Ο βασικός βρόχος αλληλεπίδρασης πράκτορα/περιβάλλοντος στην Ενισχυτική Μάθηση. Ο πράκτορας εκτελεί δράσεις και το περιβάλλον αποκρίνεται με νέα κατάσταση και ανταμοιβή.	13
3.2. Πολυεπίπεδο Δίκτυο Πρόσθιας Τροφοδότησης (Multi-Layer Perceptron) με ένα κρυφό στρώμα. Η πληροφορία ρέει μονόδρομα από την είσοδο προς την έξοδο.	14
3.3. Αρχιτεκτονική Actor/Critic. Ο Critic εκτιμά την αξία της κατάστασης και τροφοδοτεί τον Actor με το σήμα πλεονεκτήματος A_t , το οποίο κατευθύνει την ενημέρωση της πολιτικής.	25
3.4. Δομή ενός ανοδικού (αριστερά) και ενός πτωτικού (δεξιά) κεριού. Το σώμα ορίζεται από το άνοιγμα και το κλείσιμο, ενώ οι σκιές δείχνουν το εύρος υψηλότερης–χαμηλότερης τιμής εντός του διαστήματος.	32

List of Tables

3.1. Σύνοψη βασικών συναρτήσεων ενεργοποίησης και των ιδιοτήτων τους. . . .	16
3.2. Ταξινόμηση βασικών οικογενειών αλγορίθμων Ενισχυτικής Μάθησης. . . .	25
3.3. Βασικά μέτρα αξιολόγησης απόδοσης στρατηγικών συναλλαγών.	34

1.1. Πλαίσιο & Κίνητρο

Η Τεχνητή Νοημοσύνη (Artificial Intelligence, AI) αποτελεί ένα ταχέως εξελισσόμενο επιστημονικό και τεχνολογικό πεδίο με εφαρμογή σε πολλούς κλάδους της ανθρώπινης δραστηριότητας. Ασχολείται με τη σχεδίαση και υλοποίηση υπολογιστικών συστημάτων ικανών να αναπαράγουν γνωστικές λειτουργίες ενός ανθρώπου όπως είναι η μάθηση, ο σχεδιασμός, η δημιουργικότητα, η προσαρμοστικότητα, η εξαγωγή συμπερασμάτων, η κατανόηση από συμφραζόμενα, η επίλυση προβλημάτων και άλλες.

Η Μηχανική Μάθηση (Machine Learning, ML) αποτελεί έναν από τους σημαντικότερους κλάδους της Τεχνητής Νοημοσύνης, καθώς παρέχει τη δυνατότητα ανάπτυξης συστημάτων που βελτιώνουν την απόδοσή τους μέσω της εμπειρίας και της ανάλυσης δεδομένων [35]. Ανάμεσα στις επιμέρους προσεγγίσεις της, η Βαθιά Μάθηση (Deep Learning, DL) έχει αναδειχθεί ως ιδιαίτερα αποτελεσματική στην αντιμετώπιση σύνθετων προβλημάτων υψηλής διάστασης, αξιοποιώντας πολυεπίπεδα νευρωνικά δίκτυα για την αυτόματη εξαγωγή αναπαραστάσεων και προτύπων από τα δεδομένα [31]. Παράλληλα, η Ενισχυτική Μάθηση (Reinforcement Learning, RL) επικεντρώνεται στη μάθηση μέσω αλληλεπίδρασης με το περιβάλλον, επιτρέποντας σε έναν πράκτορα να προσαρμόζει τη συμπεριφορά του με βάση τις ανταμοιβές που λαμβάνει [50]. Ο συνδυασμός των δύο αυτών περιοχών οδήγησε στη Βαθιά Ενισχυτική Μάθηση (Deep Reinforcement Learning, DRL), η οποία έχει επιτύχει αξιοσημείωτα αποτελέσματα σε προβλήματα ακολουθιακής λήψης αποφάσεων, όπως η ρομποτική, τα αυτόνομα συστήματα, η υγειονομική περίθαλψη και οι χρηματοοικονομικές συναλλαγές [3].

Η ανάπτυξη τεχνικών βαθιάς μάθησης έχει επιταχύνει σημαντικά την πρόοδο σε προβλήματα αντίληψης, πρόβλεψης και λήψης αποφάσεων υπό αβεβαιότητα [18]. Οι χρηματοοικονομικές συναλλαγές αποτελούν ένα ιδιαίτερα απαιτητικό πεδίο εφαρμογής της [4]. Σε αντίθεση με κλασικά προβλήματα πρόβλεψης, ο στόχος δεν είναι μόνο η εκτίμηση της μελλοντικής πορείας μιας τιμής, αλλά η λήψη κατάλληλων αποφάσεων αγοράς, πώλησης ή διακράτησης υπό συνθήκες αβεβαιότητας. Παρόλα αυτά, οι αγορές χαρακτηρίζονται από υψηλό θόρυβο,

μεταβαλλόμενα καθεστώτα λειτουργίας, ισχυρή χρονική εξάρτηση και σημαντικά κόστη συναλλαγών, παράγοντες που καθιστούν δύσκολη τη γενίκευση των μοντέλων σε νέα δεδομένα.

Τα τελευταία χρόνια, σημαντικό μέρος της έρευνας έχει επικεντρωθεί στην αξιοποίηση νευρωνικών δικτύων και αλγορίθμων ενισχυτικής μάθησης για την ανάπτυξη αυτόνομων πρακτόρων συναλλαγών [38]. Σε αντίθεση με τις κλασικές προσεγγίσεις πρόβλεψης τιμών, η DRL βελτιστοποιεί άμεσα τη διαδοχική λήψη αποφάσεων μέσω συνάρτησης ανταμοιβής που μπορεί να ενσωματώνει κέρδος, κίνδυνο και κόστη συναλλαγών. Κάτι που είναι ιδιαίτερα χρήσιμο σε περιβάλλοντα υψηλού θορύβου και μη στασιμότητας τα οποία χαρακτηρίζονται μερικώς παρατηρήσιμα (Partially Observable Markov Decision Process, POMDP) όπως οι χρηματοοικονομικές αγορές (stocks, crypto), με το πραγματικό καθεστώς της αγοράς να μην είναι άμεσα ορατό.

Ωστόσο, οι περισσότερες προσεγγίσεις DRL βασίζονται κυρίως σε αριθμητικά δεδομένα αγοράς, όπως ιστορικές τιμές και τεχνικούς δείκτες, παραβλέποντας πληροφορία που προέρχεται από άλλες πηγές [27]. Παράλληλα, η αυξανόμενη διαθεσιμότητα ειδήσεων, οικονομικών αναφορών, αναρτήσεων και σχολιασμών στα μέσα κοινωνικής δικτύωσης έχει αναδείξει τη σημασία της ανάλυσης συναισθήματος (sentiment analysis) ως πιθανής πηγής πληροφορίας για την ερμηνεία της συμπεριφοράς των αγορών [9].

Η πρόσφατη ανάπτυξη των Μεγάλων Γλωσσικών Μοντέλων (Large Language Models, LLMs) έχει βελτιώσει σημαντικά την ικανότητα εξαγωγής σημασιολογικής πληροφορίας από κείμενο [10]. Παρότι τα μοντέλα αυτά έχουν εφαρμοστεί με επιτυχία σε προβλήματα επεξεργασίας φυσικής γλώσσας, η αποτελεσματική ενσωμάτωση των πληροφοριών που παράγουν σε συστήματα λήψης αποφάσεων για χρηματοοικονομικές συναλλαγές παραμένει ενεργό ερευνητικό ζήτημα.

1.2. Διατύπωση προβλήματος

Το πρόβλημα των χρηματοοικονομικών συναλλαγών μπορεί να διατυπωθεί ως πρόβλημα ακολουθιακής λήψης αποφάσεων, όπου ένας πράκτορας παρατηρεί την κατάσταση της αγοράς και επιλέγει ενέργειες με σκοπό τη μεγιστοποίηση μιας συνάρτησης ανταμοιβής που σχετίζεται με την απόδοση του χαρτοφυλακίου του. Η διατύπωση αυτή συνοδεύεται από σημαντικές δυσκολίες λόγω της μη στασιμότητας των αγορών, του θορύβου των δεδομένων και της περιορισμένης παρατηρησιμότητας του πραγματικού υποκείμενου καθεστώτος της αγοράς.

Επιπλέον, η διαθέσιμη πληροφορία δεν περιορίζεται στα αριθμητικά δεδομένα που προκύπτουν από τις τιμές των περιουσιακών στοιχείων. Η δημοσίευση ειδήσεων, οικονομικών γεγονότων ή η μεταβολή του επενδυτικού κλίματος μπορεί να επηρεάσει σημαντικά τη συμπεριφορά της αγοράς, ιδίως σε περιουσιακά στοιχεία υψηλής μεταβλητότητας όπως τα κρυπτονομίσματα. Παρότι μέρος αυτής της πληροφορίας αποτυπώνεται τελικά στις τιμές, δεν

είναι σαφές κατά πόσο η αξιοποίησή της σε πρώιμο στάδιο μπορεί να βελτιώσει τη διαδικασία λήψης αποφάσεων ενός πράκτορα συναλλαγών.

Η παρούσα εργασία εξετάζει κατά πόσο ένα σήμα συναισθήματος που παράγεται από ένα προσαρμοσμένο LLM μπορεί να λειτουργήσει συμπληρωματικά προς τα κλασικά χαρακτηριστικά αγοράς και να βελτιώσει την απόδοση ενός πράκτορα Βαθιάς Ενισχυτικής Μάθησης (DRL).

1.3. Στόχος και προτεινόμενη προσέγγιση

Στόχος της παρούσας εργασίας είναι η ανάπτυξη και αξιολόγηση ενός προσαρμοστικού πράκτορα χρηματοοικονομικών συναλλαγών που συνδυάζει πληροφορία αγοράς με πληροφορία προερχόμενη από χρηματοοικονομικά κείμενα. Η βασική ιδέα είναι ότι το κειμενικό σήμα μπορεί να προσφέρει συμπληρωματική πληροφορία σε σχέση με τα κλασικά αριθμητικά χαρακτηριστικά αγοράς, ιδιαίτερα σε περιόδους όπου η μεταβλητότητα, η αβεβαιότητα ή η κατεύθυνση της τάσης καθορίζονται σε σημαντικό βαθμό από την πληροφόρηση και τη συλλογική ψυχολογία.

Για τον σκοπό αυτό, ο προτεινόμενος προσαρμοστικός πράκτορας αποτελείται από δύο διακριτούς αλλά συμπληρωματικούς κορμούς:

1. **Ο πρώτος κορμός** αφορά την παραγωγή sentiment με τη χρήση ενός LLM, το οποίο έχει προσαρμοστεί στο πεδίο της χρηματοοικονομικής/επενδυτικής γλώσσας με χρήση τεχνικών αποδοτικής εκπαίδευσης παραμέτρων, συγκεκριμένα με Low Rank Adaptation (LoRA), αξιοποιώντας σχετικά δεδομένα από άρθρα και αναρτήσεις σε κοινωνικά δίκτυα. Στόχος είναι η εξαγωγή ενός αριθμητικού δείκτη sentiment που να είναι σταθερός, αναπαραγώγιμος και κατάλληλος για συγχρονισμό με χρονικά βήματα αγοράς.
2. **Ο δεύτερος κορμός** αφορά έναν πράκτορα ενισχυτικής μάθησης (DRL) με βαθύ αναδρομικό νευρωνικό δίκτυο (Long Short-Term Memory, LSTM), ο οποίος εκπαιδεύεται με Proximal Policy Optimization (PPO). Η LSTM αρχιτεκτονική επιτρέπει την αξιοποίηση χρονικών εξαρτήσεων και τη διατήρηση μνήμης, κάτι που είναι κρίσιμο σε POMDP πλαίσιο όπου το ιστορικό φέρει πληροφορία για το καθεστώς της αγοράς.

Το sentiment αξιοποιείται διττά:

- (α) ως πρόσθετο χαρακτηριστικό εισόδου (feature) του μοντέλου DRL, ώστε να εμπλουτίζει την κατάσταση (state) του περιβάλλοντος (environment) με κειμενικά-σημασιολογική πληροφορία, και
- (β) ως σήμα ενίσχυσης/μείωσης (amplify/reduce) της έντασης των ενεργειών (actions) του πράκτορα υπό συγκεκριμένες συνθήκες.

Με αυτόν τον τρόπο, το sentiment δεν αντιμετωπίζεται απλώς ως παθητικό χαρακτηριστικό, αλλά ως παράγοντας που μπορεί να επηρεάζει λειτουργικά την εκτελεστική συμπεριφορά του πράκτορα, επιτρέποντας στη στρατηγική να γίνεται πιο επιθετική ή πιο αμυντική ανάλογα με το πληροφοριακό περιεχόμενο του κειμενικού σήματος.

1.4. Συνεισφορές

Οι κύριες συνεισφορές της παρούσας εργασίας συνοψίζονται στα ακόλουθα:

- Προτείνεται μία υβριδική αρχιτεκτονική που συνδυάζει LLM-based sentiment analysis και DRL για χρηματοοικονομικές συναλλαγές.
- Υλοποιείται προσαρμογή ενός LLM με χρήση LoRA για την εξαγωγή sentiment από χρηματοοικονομικά κείμενα.
- Διερευνάται η διττή αξιοποίηση του sentiment ως χαρακτηριστικού κατάστασης και ως μηχανισμού προσαρμογής των ενεργειών ενός PPO-LSTM πράκτορα.
- Παρουσιάζεται εκτενής πειραματική αξιολόγηση σε περιβάλλον συναλλαγών κρυπτονομισμάτων.

1.5. Δομή Εργασίας

Η εργασία οργανώνεται ως εξής. Στο Κεφάλαιο 2 παρουσιάζεται η σχετική βιβλιογραφία και η επισκόπηση της ερευνητικής περιοχής. Στο Κεφάλαιο 3 αναλύεται το απαραίτητο θεωρητικό υπόβαθρο. Στο Κεφάλαιο 4 περιγράφεται η προτεινόμενη μεθοδολογία και η αρχιτεκτονική του συστήματος. Στο Κεφάλαιο 5 παρουσιάζονται τα πειραματικά αποτελέσματα και η αξιολόγηση της προτεινόμενης προσέγγισης. Τέλος, στο Κεφάλαιο 6 συνοψίζονται τα συμπεράσματα της εργασίας και διατυπώνονται προτάσεις για μελλοντική έρευνα.

Επισκόπηση της Ερευνητικής Περιοχής

2.1. Από τα Κλειστά Προσομοιωμένα Περιβάλλοντα στα Ανοιχτά Στοχαστικά Συστήματα

Η εντυπωσιακή πρόοδος της DRL συνδέεται ιστορικά με την επίτευξη επιδόσεων ανώτερων του ανθρώπινου επιπέδου (superhuman performance) σε κλειστά, προσομοιωμένα περιβάλλοντα παιχνιδιών. Ορόσημα όπως η επιτυχία του αλγορίθμου Deep Q-Network (DQN) στο περιβάλλον Atari [37] και η επικράτηση του AlphaGo στο απαιτητικό παιχνίδι του Go [48] απέδειξαν την ικανότητα των πρακτόρων DRL να επιλύουν σύνθετα προβλήματα ακολουθιακής λήψης αποφάσεων υψηλής διάστασης.

Ωστόσο, τα περιβάλλοντα αυτά χαρακτηρίζονται από πλήρη παρατηρησιμότητα (Fully Observable MDPs), σταθερούς ντετερμινιστικούς κανόνες και τη δυνατότητα δημιουργίας απεριόριστων δεδομένων μέσω εξομοίωσης (Synthetic Data). Η προσπάθεια μεταφοράς αυτών των μοντέλων σε πραγματικά, ανοιχτά συστήματα, όπως η ρομποτική και η αυτόνομη οδήγηση, ανέδειξε σημαντικές προκλήσεις που σχετίζονται με τον θόρυβο των αισθητήρων, την περιορισμένη παρατηρησιμότητα και τη μη στασιμότητα (non-stationarity) του περιβάλλοντος [30].

Για την αντιμετώπιση αυτών των περιορισμών, η έρευνα στράφηκε προς δύο κατευθύνσεις: (α) την ενσωμάτωση αναδρομικών επιπέδων (DRQN / LSTM) για τη διατήρηση ιστορικής μνήμης σε POMDP, και (β) την ανάπτυξη αλγορίθμων Policy Gradient με περιορισμούς στο μέγεθος του βήματος ενημέρωσης (Trust Region), όπως ο PPO [46], οι οποίοι προσφέρουν σταθερότητα κάτω από συνθήκες έντονου θορύβου.

Η συγκεκριμένη μεθοδολογική εξέλιξη κρίνεται ως απολύτως αναγκαία για τη μεταφορά του DRL στο χρηματοοικονομικό πεδίο, το οποίο αποτελεί ίσως το πιο ακραίο παράδειγμα ανοιχτού, στοχαστικού και μη στασίμου περιβάλλοντος.

2.2. Τεχνητή Νοημοσύνη και Μηχανική Μάθηση στις Αγορές

Η εφαρμογή αλγορίθμων ML για την ανάλυση και πρόβλεψη χρηματοοικονομικών χρονοσειρών αποτελεί αντικείμενο εκτενούς έρευνας εδώ και δεκαετίες. Οι παραδοσιακές στατιστικές μέθοδοι ανάλυσης χρονοσειρών, όπως η AutoRegressive Integrated Moving Average (ARIMA) και οι παραλλαγές της: Generalized Auto-Regressive Conditional Heteroscedasticity (GARCH) και Autoregressive Moving Average (ARMA), αλλά και τα Μοντέλα Παλινδρόμησης (Regression Models), αντικαταστάθηκαν σταδιακά από επιβλεπόμενες (supervised) τεχνικές μηχανικής μάθησης, όπως οι Μηχανές Διανυσμάτων Υποστήριξης (Support Vector Machines - SVM) και τα Τυχαία Δάση (Random Forests) [40].

Οι προσεγγίσεις αυτές επικεντρώθηκαν κυρίως στην κατηγοριοποίηση της κατεύθυνσης της τιμής (άνοδος/πτώση) ή στην παλινδρόμηση για την εκτίμηση της μελλοντικής απόδοσης. Παρά την αρχική τους επιτυχία, τα κλασικά μοντέλα ML παρουσιάζουν σημαντικούς περιορισμούς όταν καλούνται να διαχειριστούν τη μη γραμμικότητα, τον υψηλό θόρυβο και τη μη στασιμότητα (non-stationarity) που χαρακτηρίζουν τις σύγχρονες διεθνείς αγορές.

2.3. Βαθιά Μάθηση στις Χρηματοοικονομικές Συναλλαγές

Η έλευση της Βαθιάς Μάθησης (Deep Learning) επέτρεψε την αυτόματη εξαγωγή σύνθετων, μη γραμμικών αναπαραστάσεων από ακατέργαστα δεδομένα αγοράς (raw market data), εξαλείφοντας την ανάγκη για χειροκίνητο σχεδιασμό χαρακτηριστικών (manual feature engineering).

Τα Αναδρομικά Νευρωνικά Δίκτυα (Recurrent Neural Networks - RNNs) και ειδικότερα η αρχιτεκτονική Long Short-Term Memory (LSTM) καθιερώθηκαν ως η κυρίαρχη επιλογή για τη μοντελοποίηση χρηματοοικονομικών δεδομένων, λόγω της ικανότητάς τους να διατηρούν πληροφορίες για μεγάλα χρονικά διαστήματα και να διαχειρίζονται χρονικές εξαρτήσεις [17]. Παράλληλα, τα Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNNs) έχουν χρησιμοποιηθεί με επιτυχία για την αναγνώριση οπτικών προτύπων σε διαγράμματα τιμών (chart patterns) ή για τη γεωμετρική αναπαράσταση των βιβλίων εντολών (limit order books) [57].

Ωστόσο, η βιβλιογραφία αναδεικνύει ότι η απλή πρόβλεψη της τιμής (price forecasting) δεν μεταφράζεται απαραίτητα σε κερδοφόρα στρατηγική συναλλαγών, καθώς δεν λαμβάνει υπόψη τους περιορισμούς εκτέλεσης, τα κόστη συναλλαγών και τη δυναμική διαχείριση του κινδύνου.

2.4. Ενισχυτική Μάθηση και Ακολουθιακή Λήψη Αποφάσεων

Για την γεφύρωση του χάσματος μεταξύ πρόβλεψης και εκτέλεσης, η έρευνα στράφηκε προς την Ενισχυτική Μάθηση (RL). Σε αντίθεση με τις κλασικές προσεγγίσεις επιβλεπόμενης μάθησης (supervised learning), στις οποίες το μοντέλο εκπαιδεύεται να αναπαράγει ζεύγη εισόδου-εξόδου που παρέχονται από ανθρώπινη επισήμανση, οι πράκτορες RL δεν εκπαιδεύονται να ελαχιστοποιούν ένα σφάλμα πρόβλεψης, αλλά να μεγιστοποιούν μια μακροπρόθεσμη συνάρτηση χρησιμότητας (όπως η σωρευτική απόδοση ή ο δείκτης Sharpe) μέσω της αλληλεπίδρασης με την αγορά.

Οι πρώτες απόπειρες βασίστηκαν σε tabular μεθόδους (Q-learning), αλλά ο συνδυασμός με τη βαθιά μάθηση (Deep Reinforcement Learning - DRL) επέτρεψε τη διαχείριση συνεχών και υψηλής διάστασης καταστάσεων (state spaces) [32]. Αλγόριθμοι που βασίζονται στην πολιτική (Policy Gradient methods), όπως ο Proximal Policy Optimization (PPO), έχουν επιδείξει εξαιρετική σταθερότητα σε περιβάλλοντα συναλλαγών [56].

Η ενσωμάτωση αναδρομικών επιπέδων (PPO-LSTM) επέτρεψε τη μοντελοποίηση της αγοράς ως POMDP, αναγνωρίζοντας ότι οι ιστορικές τιμές κρύβουν πληροφορίες για το μη εμφανές καθεστώς της αγοράς (market regime).

2.5. Ανάλυση Συναισθήματος και Εναλλακτικά Δεδομένα

Παρά την εξέλιξη των DRL πρακτόρων, η αποκλειστική χρήση ποσοτικών/αριθμητικών δεδομένων (ενδογενή δεδομένα αγοράς) θεωρείται από πολλούς ερευνητές ανεπαρκής, καθώς αντανακλά γεγονότα που έχουν ήδη συμβεί. Η θεωρία της Ημι-Ισχυρής Αποτελεσματικής Αγοράς (Semi-Strong Efficient Market Hypothesis, EMH) προβλέπει ότι οι τρέχουσες τιμές αντικατοπτρίζουν πλήρως το σύνολο των δημοσίως διαθέσιμων πληροφοριών, στις οποίες περιλαμβάνονται οικονομικές καταστάσεις εταιρειών, μακροοικονομικά στοιχεία, εκθέσεις αναλυτών και ειδησεογραφικές ανακοινώσεις [16]. Το βασικό εμπειρικό συμπέρασμα της υπόθεσης αυτής είναι ότι οι τιμές προσαρμόζονται ταχέως και πλήρως με την έλευση κάθε νέας δημόσιας πληροφορίας, αφήνοντας ελάχιστο περιθώριο για τη θεμελιώδη ανάλυση (fundamental analysis) να παράγει συστηματικά αποδόσεις που υπερβαίνουν αυτές της αγοράς. Ωστόσο, η εμπειρική βιβλιογραφία έχει τεκμηριώσει αριθμό ανωμαλιών που προκαλούν αμφισβητήσεις στην αυστηρή της εκδοχή. Χαρακτηριστική περίπτωση αποτελεί το φαινόμενο Post-Earnings-Announcement Drift (PEAD), σύμφωνα με το οποίο οι τιμές των μετοχών συνεχίζουν να κινούνται προς την κατεύθυνση της αρχικής αντίδρασης σε αποτελέσματα κερδών για εβδομάδες μετά την ανακοίνωση [7], αντίθετα με την πρόβλεψη της ημι-ισχυρής EMH για άμεση τιμολόγηση. Στο πλαίσιο της παρούσας εργασίας, η θεωρία αυτή θεμελιώνει

τη σκοπιμότητα της ενσωμάτωσης δεδομένων κειμένου ως εξωγενούς σήματος, δεδομένου ότι πληροφορίες που εμφανίζονται πρώτα σε γλωσσική μορφή ενδέχεται να προηγούνται της πλήρους τιμολόγησής τους στην αγορά.

2.5.1. Οικονομικές Ειδήσεις και Μέσα Κοινωνικής Δικτύωσης

Η ανάλυση συναισθήματος (Sentiment Analysis) σε χρηματοοικονομικά κείμενα χωρίζεται ιστορικά σε δύο κύριες πηγές:

1. **Επίσημες Χρηματοοικονομικές Ειδήσεις:** Πηγές όπως το Bloomberg, το Reuters ή εταιρικές ανακοινώσεις παρέχουν θεσμική, υψηλής εγκυρότητας πληροφορία που επηρεάζει κυρίως τις παραδοσιακές αγορές (μετοχές, ομόλογα) [52].
2. **Μέσα Κοινωνικής Δικτύωσης (Social Media):** Πλατφόρμες όπως το Twitter/X και το Reddit παράγουν δεδομένα υψηλής συχνότητας. Η βιβλιογραφία δείχνει ότι το περιεχόμενο αυτό είναι ιδιαίτερα κρίσιμο για περιουσιακά στοιχεία με υψηλό βαθμό κερδοσκοπίας και λιανικής συμμετοχής, όπως τα κρυπτονομίσματα, όπου η συλλογική ψυχολογία καθορίζει συχνά βραχυπρόθεσμες τάσεις [9].

2.5.2. Από τα Λεξικά στα Μεγάλα Γλωσσικά Μοντέλα (LLMs)

Οι πρώτες μέθοδοι εξαγωγής συναισθήματος βασίστηκαν σε στατικά λεξικά προσαρμοσμένα στα χρηματοοικονομικά, όπως το λεξικό Loughran-McDonald [34]. Αν και αποτελεσματικές για την εποχή τους, οι μέθοδοι αυτές αδυνατούσαν να συλλάβουν το συντακτικό πλαίσιο, τον σαρκασμό ή τις πολύπλοκες σημασιολογικές δομές.

Η εισαγωγή αρχιτεκτονικών Transformer (π.χ. FinBERT) βελτίωσε δραστικά την κατάσταση, προσφέροντας contextual αναπαραστάσεις [2]. Πρόσφατα, η έρευνα έχει μετατοπιστεί στα LLMs, όπως οι παραλλαγές των LLaMA, GPT και εξειδικευμένων μοντέλων όπως το FinGPT [55]. Τα μοντέλα αυτά, όταν προσαρμόζονται με αποδοτικές μεθόδους (Parameter-Efficient Fine-Tuning, PEFT), όπως το Low-Rank Adaptation (LoRA), επιδεικνύουν σημαντικά βελτιωμένη ικανότητα zero-shot και few-shot συλλογιστικής, δηλαδή την ικανότητα να κατηγοριοποιούν συναίσθημα ή να εκτελούν συμπεράσματα σε νέες περιπτώσεις χωρίς (zero-shot) ή με ελάχιστα (few-shot) εκπαιδευτικά παραδείγματα. Η επίδοση αυτή, σε σύγκριση με τις παραδοσιακές λεξιλογικές μεθόδους (lexicon-based approaches), τεκμηριώνεται εμπειρικά σε ποικίλα χρηματοοικονομικά σενάρια αξιολόγησης [55], επιτρέποντας πιο αξιόπιστη ποσοτικοποίηση του επενδυτικού κλίματος από κειμενικές πηγές.

Η ενοποίηση αυτών των LLM-based σημάτων συναισθήματος ως εξωγενών μεταβλητών σε DRL συστήματα λήψης αποφάσεων αποτελεί την τρέχουσα αιχμή του δόρατος στην

αλγοριθμική έρευνα, με ανοιχτά ζητήματα που αφορούν τον βέλτιστο τρόπο σύντηξης (data fusion) των δύο αυτών διαφορετικών κόσμων (κειμενικού και αριθμητικού).

Θεωρητικό Υπόβαθρο

Το παρόν κεφάλαιο παραθέτει την αναλυτική θεωρητική θεμελίωση των εννοιών, των αρχιτεκτονικών και των αλγορίθμων που συγκροτούν τον πυρήνα της προτεινόμενης μεθοδολογίας. Στόχος είναι, αφενός να καταστήσει την εργασία αυτοτελή, ώστε ο αναγνώστης να μην απαιτείται να ανατρέξει σε εξωτερικές πηγές για τις βασικές έννοιες, και αφετέρου να αναδείξει με σαφήνεια κάθε επιμέρους τεχνική που χρησιμοποιήθηκε στο πλαίσιο της εργασίας.

Η ανάπτυξη ακολουθεί μια λογική «από το γενικό στο ειδικό». Αρχικά (Ενότητα 3.1) εισάγονται οι θεμελιώδεις αρχές της Μηχανικής Μάθησης και τα τρία βασικά της παραδείγματα. Στη συνέχεια (Ενότητα 3.2) αναλύονται τα Τεχνητά Νευρωνικά Δίκτυα και η Βαθιά Μάθηση, με ιδιαίτερη έμφαση στις συναρτήσεις ενεργοποίησης, στις συναρτήσεις κόστους, στη διαδικασία εκπαίδευσης και στα αναδρομικά δίκτυα Μακράς Βραχύχρονης Μνήμης (LSTM), τα οποία αποτελούν τον σπονδυλικό άξονα του πράκτορα. Ακολούθως (Ενότητα 3.3) θεμελιώνεται μαθηματικά η Βαθιά Ενισχυτική Μάθηση, ξεκινώντας από τις Μαρκοβιανές Διαδικασίες Απόφασης (MDP) και τις γενικεύσεις τους POMDP και Constrained Markov Decision Process (CMDP), περνώντας από τις εξισώσεις Bellman και καταλήγοντας στον αλγόριθμο Proximal Policy Optimization (PPO). Η Ενότητα 3.4 παρουσιάζει τα Μεγάλα Γλωσσικά Μοντέλα, την ανάλυση συναισθήματος και την αποδοτική μικρο-προσαρμογή με Low-Rank Adaptation (LoRA), ως μηχανισμός εξειδίκευσης του γλωσσικού μοντέλου στη χρηματοοικονομική γλώσσα. Τέλος, η Ενότητα 3.5 εισάγει τις απαραίτητες έννοιες των χρηματοοικονομικών αγορών, της δομής των δεδομένων, της μέτρησης κέρδους/ζημίας (Profit and Loss, PnL) και του ενεργού κέρδους (α), και κλείνει με την επισκόπηση του ρόλου της Τεχνητής Νοημοσύνης στις συναλλαγές.

3.1. Μηχανική Μάθηση

Η Μηχανική Μάθηση (Machine Learning, ML) αποτελεί κλάδο της Τεχνητής Νοημοσύνης που εστιάζει στην ανάπτυξη υπολογιστικών μοντέλων ικανών να βελτιώνουν την απόδοσή τους σε μια εργασία μέσω της εμπειρίας, χωρίς να απαιτείται ρητός, χειροκίνητος

προγραμματισμός των κανόνων που διέπουν τη λύση [35, 8]. Με την κλασική διατύπωση του Mitchell, ένα πρόγραμμα μαθαίνει από την εμπειρία E ως προς μια κατηγορία εργασιών T και ένα μέτρο απόδοσης P , εάν η απόδοσή του στις εργασίες T , μετρημένη με το P , βελτιώνεται με την εμπειρία E .

Σε τυπικό επίπεδο, δεδομένου ενός χώρου εισόδων $\mathcal{X}$ και ενός χώρου εξόδων $\mathcal{Y}$, αναζητούμε μια συνάρτηση $f_\theta : \mathcal{X} \rightarrow \mathcal{Y}$ παραμετροποιημένη από ένα διάνυσμα παραμέτρων θ , η οποία ελαχιστοποιεί έναν *αναμενόμενο κίνδυνο* (expected risk):

$$R(f_\theta) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_\theta(x), y)], \quad (3.1)$$

όπου $\mathcal{D}$ είναι η (άγνωστη) κοινή κατανομή των δεδομένων και ℓ μια συνάρτηση απώλειας. Επειδή η $\mathcal{D}$ είναι άγνωστη, στην πράξη ελαχιστοποιούμε τον *εμπειρικό κίνδυνο* (empirical risk) πάνω σε ένα πεπερασμένο σύνολο N παρατηρήσεων:

$$\hat{R}(f_\theta) = \frac{1}{N} \sum_{i=1}^N \ell(f_\theta(x_i), y_i). \quad (3.2)$$

Η αρχή αυτή, γνωστή ως *ελαχιστοποίηση εμπειρικού κινδύνου* (Empirical Risk Minimization), είναι θεμελιώδης για το σύνολο της επιβλεπόμενης μάθησης.

Κεντρικό ζήτημα της Μηχανικής Μάθησης είναι η *γενίκευση* (generalization): η ικανότητα του μοντέλου να αποδίδει καλά σε νέα, άγνωστα δεδομένα και όχι μόνο σε εκείνα της εκπαίδευσης. Η ισορροπία μεταξύ *μεροληψίας* (bias) και *διακύμανσης* (variance) [19] περιγράφει τον αντισταθμιστικό συσχετισμό ανάμεσα σε ένα υπερβολικά απλό μοντέλο που υποπροσαρμόζει (underfitting) και σε ένα υπερβολικά σύνθετο μοντέλο που υπερπροσαρμόζει (overfitting) τον θόρυβο των δεδομένων. Όπως θα φανεί στην Ενότητα 3.5, στο χρηματοοικονομικό πεδίο το ζήτημα της υπερπροσαρμογής είναι ιδιαίτερος οξύ λόγω του χαμηλού λόγου σήματος προς θόρυβο (Signal to Noise Ratio, SNR) των αγορών.

Η Μηχανική Μάθηση διακρίνεται παραδοσιακά σε τρία βασικά παραδείγματα, τα οποία διαφέρουν ως προς τη φύση του σήματος εποπτείας που είναι διαθέσιμο κατά την εκπαίδευση.

3.1.1. Επιβλεπόμενη Μάθηση

Στην Επιβλεπόμενη Μάθηση (Supervised Learning) το μοντέλο εκπαιδεύεται σε ένα σύνολο ζευγών εισόδου/εξόδου $\mathcal{S} = \{(x_i, y_i)\}_{i=1}^N$, όπου κάθε είσοδος x_i συνοδεύεται από μια γνωστή ετικέτα-στόχο y_i (label). Σκοπός είναι η εκμάθηση μιας συνάρτησης που αντιστοιχίζει εισόδους σε επιθυμητές εξόδους, ώστε να μπορεί να προβλέπει την ετικέτα νέων, μη επισημασμένων δειγμάτων [8].

Ανάλογα με τη φύση της εξόδου $\mathcal{Y}$, διακρίνουμε δύο υποκατηγορίες:

- Την **ταξινόμηση** (classification), όπου ο χώρος εξόδου είναι διακριτός και πεπερα-

σμένος (π.χ. πρόβλεψη ανόδου/πτώσης/ουδετερότητας της τιμής ενός περιουσιακού στοιχείου).

- Την **παλινδρόμηση** (regression), όπου ο χώρος εξόδου είναι συνεχής (π.χ. πρόβλεψη της μελλοντικής απόδοσης ή της μεταβλητότητας μιας μετοχής).

Τυπικά παραδείγματα επιβλεπόμενων αλγορίθμων αποτελούν η Γραμμική και η Λογιστική Παλινδρόμηση, οι Μηχανές Διανυσμάτων Υποστήριξης (Support Vector Machines, SVMs), τα Δέντρα Απόφασης (Decision Trees) και τα Τυχαία Δάση (Random Forests), καθώς και τα Νευρωνικά Δίκτυα που αναλύονται στην Ενότητα 3.2. Στον τομέα των χρηματοοικονομικών χρονοσειρών, η επιβλεπόμενη μάθηση αξιοποιείται κατεξοχήν για την κατασκευή μοντέλων πρόβλεψης, ωστόσο η ακριβής πρόβλεψη μιας τιμής δεν συνεπάγεται αναγκαστικά κερδοφόρα συναλλακτική στρατηγική: αποτυγχάνει να μοντελοποιήσει τη δυναμική των εντολών, τα κόστη συναλλαγών και τη διαχείριση κινδύνου κατά μήκος μιας ακολουθίας αποφάσεων. Αυτή η θεμελιώδης ανεπάρκεια δικαιολογεί τη στροφή προς παραδείγματα *ακολουθιακής λήψης αποφάσεων*, και ειδικότερα προς την Ενισχυτική Μάθηση, που αναλύεται στην Ενότητα 3.1.3.

3.1.2. Μη Επιβλεπόμενη Μάθηση

Στη Μη Επιβλεπόμενη Μάθηση (Unsupervised Learning) δεν υπάρχουν ετικέτες/στόχοι, αλλά το σύστημα διαθέτει αποκλειστικά τα δεδομένα εισόδου $\{x_i\}_{i=1}^N$ και καλείται να ανακαλύψει αυτόνομα κρυφές δομές, κανονικότητες ή μοτίβα [19]. Οι κύριες κατηγορίες εργασιών είναι:

- Η **συσταδοποίηση** (clustering), όπου οι παρατηρήσεις ομαδοποιούνται με βάση κάποιο μέτρο ομοιότητας (π.χ. k-means, ιεραρχική συσταδοποίηση). Στα χρηματοοικονομικά, η συσταδοποίηση χρησιμοποιείται για την αναγνώριση διακριτών *καθεστώτων αγοράς* (market regimes), όπως περίοδοι χαμηλής ή υψηλής μεταβλητότητας.
- Η **μείωση διαστάσεων** (dimensionality reduction), όπου επιδιώκεται η συμπίεση αναπαράσταση δεδομένων υψηλής διάστασης σε χαμηλότερο χώρο διατηρώντας την ουσιαστική πληροφορία (π.χ. Ανάλυση Κύριων Συνιστωσών, Principal Component Analysis, PCA, αυτοκωδικοποιητές).
- Η **εκτίμηση πυκνότητας** (density estimation) και τα παραγωγικά μοντέλα (generative models), που μοντελοποιούν την υποκείμενη κατανομή των δεδομένων.

Μια ιδιαιτέρως σημαντική, σύγχρονη παραλλαγή είναι η *αυτο-επιβλεπόμενη μάθηση* (self-supervised learning), στην οποία το σήμα εποπτείας παράγεται αυτόματα από τα ίδια τα δεδομένα. Αυτό το παράδειγμα αποτελεί τη βάση της προεκπαίδευσης (pre-training) των LLMs που θα εξεταστούν στην Ενότητα 3.4: το μοντέλο εκπαιδεύεται να προβλέπει την

επόμενη λέξη ή λέξεις που έχουν αποκρυφθεί, χρησιμοποιώντας ως ετικέτα (label) το ίδιο το κείμενο.

3.1.3. Ενισχυτική Μάθηση

Η Ενισχυτική Μάθηση (Reinforcement Learning, RL) διαφοροποιείται θεμελιωδώς από τα δύο προηγούμενα παραδείγματα. Εδώ δεν υπάρχει ένα στατικό σύνολο δεδομένων με «σωστές απαντήσεις», αντιθέτως, ένας *πράκτορας* (agent) αλληλεπιδρά διαδοχικά με ένα *περιβάλλον* (environment), λαμβάνοντας *ανταμοιβές* (rewards) ως αποτέλεσμα των *ενεργειών* (actions) του, και μαθαίνει μέσω δοκιμής και λάθους μια *πολιτική* [50]. Σε κάθε χρονικό βήμα t , ο πράκτορας παρατηρεί την κατάσταση s_t , επιλέγει μια δράση a_t , και λαμβάνει ανταμοιβή r_{t+1} καθώς και τη νέα κατάσταση s_{t+1} (Σχήμα 3.1).

Figure 3.1.: Ο βασικός βρόχος αλληλεπίδρασης πράκτορα/περιβάλλοντος στην Ενισχυτική Μάθηση. Ο πράκτορας εκτελεί δράσεις και το περιβάλλον αποκρίνεται με νέα κατάσταση και ανταμοιβή.

Σε αντίθεση με την επιβλεπόμενη μάθηση, το σήμα ανταμοιβής είναι συχνά *αραιό* (sparse) και *καθυστερημένο* (delayed): οι συνέπειες μιας δράσης μπορεί να εκδηλωθούν πολλά βήματα αργότερα. Αυτό δημιουργεί το λεγόμενο *πρόβλημα απόδοσης ευθύνης* (credit assignment problem). Επιπλέον, ο πράκτορας αντιμετωπίζει το δίλημμα *εξερεύνησης έναντι εκμετάλλευσης* (exploration/exploitation): πρέπει να ισορροπεί ανάμεσα στην αξιοποίηση γνωστών αποδοτικών δράσεων και στη δοκιμή νέων δράσεων που ενδέχεται να αποδειχθούν καλύτερες.

Η Ενισχυτική Μάθηση αποτελεί το φυσικό πλαίσιο για το πρόβλημα των χρηματοοικονομικών συναλλαγών, διότι αυτό είναι εγγενώς ένα πρόβλημα *ακολουθιακής λήψης αποφάσεων* υπό αβεβαιότητα: ο πράκτορας δεν ενδιαφέρεται απλώς να προβλέψει σωστά μια τιμή, αλλά να λάβει μια ακολουθία αποφάσεων που μεγιστοποιεί τη μακροπρόθεσμη, προσαρμοσμένη στον κίνδυνο απόδοση. Το πλήρες μαθηματικό πλαίσιο της RL αναπτύσσεται στην Ενότητα 3.3.

3.2. Νευρωνικά Δίκτυα και Βαθιά Μάθηση

Η Βαθιά Μάθηση (Deep Learning) αποτελεί υποκλάδο της Μηχανικής Μάθησης που βασίζεται σε Τεχνητά Νευρωνικά Δίκτυα (Artificial Neural Networks, ANNs) με πολλαπλά κρυφά στρώματα [18, 31]. Η ισχύς της έγκειται στην ικανότητά της να μαθαίνει *ιεραρχικές αναπαραστάσεις*: τα αρχικά στρώματα εξάγουν απλά, χαμηλού επιπέδου χαρακτηριστικά, ενώ τα βαθύτερα στρώματα τα συνθέτουν σε αφηρημένες, υψηλού επιπέδου έννοιες. Έτσι εξαλείφεται σε μεγάλο βαθμό η ανάγκη για χειροκίνητο σχεδιασμό χαρακτηριστικών (feature engineering).

3.2.1. Μονοεπίπεδα και Πολυεπίπεδα Δίκτυα Πρόσθιας Τροφοδότησης

Ο τεχνητός νευρώνας. Η θεμελιώδης δομική μονάδα ενός νευρωνικού δικτύου είναι ο τεχνητός νευρώνας, ένα υπολογιστικό μοντέλο εμπνευσμένο από τον βιολογικό νευρώνα. Δεχόμενος ένα διάνυσμα εισόδου $\mathbf{x} = (x_1, \dots, x_N)$, ο νευρώνας υπολογίζει έναν σταθμισμένο γραμμικό συνδυασμό των εισόδων, προσθέτει μια σταθερά μεροληψίας b (bias) και εφαρμόζει μια μη γραμμική συνάρτηση ενεργοποίησης $f(\cdot)$:

$$a = f\left(\sum_{i=1}^N w_i x_i + b\right) = f(\mathbf{w}^\top \mathbf{x} + b), \quad (3.3)$$

όπου w_i είναι τα συναπτικά βάρη. Ένας μεμονωμένος νευρώνας με βηματική συνάρτηση ενεργοποίησης συνιστά το ιστορικό μοντέλο του *αισθητήρα* (perceptron) του Rosenblatt [42].

Ο περιορισμός της γραμμικής διαχωρισιμότητας. Ένα μονοεπίπεδο δίκτυο (ένας perceptron) μπορεί να αναπαραστήσει μόνο γραμμικά διαχωρίσιμα προβλήματα. Το κλασικό αντιπαράδειγμα είναι η λογική συνάρτηση XOR, την οποία κανένα γραμμικό όριο απόφασης δεν μπορεί να διαχωρίσει. Η υπέρβαση αυτού του περιορισμού απαιτεί τη διάταξη πολλαπλών στρωμάτων νευρώνων.

Figure 3.2.: Πολυεπίπεδο Δίκτυο Πρόσθιας Τροφοδότησης (Multi-Layer Perceptron) με ένα κρυφό στρώμα. Η πληροφορία ρέει μονόδρομα από την είσοδο προς την έξοδο.

Πολυεπίπεδα Δίκτυα Πρόσθιας Τροφοδότησης. Ένα Πολυεπίπεδο Δίκτυο Πρόσθιας Τροφοδότησης (Multi-Layer Perceptron, MLP) οργανώνει τους νευρώνες σε διαδοχικά στρώματα: ένα στρώμα εισόδου, ένα ή περισσότερα κρυφά στρώματα και ένα στρώμα εξόδου (Σχήμα 3.2). Ο χαρακτηρισμός «πρόσθιας τροφοδότησης» (feedforward) δηλώνει ότι η πληροφορία ρέει μονόδρομα, χωρίς κύκλους. Αν συμβολίσουμε με $\mathbf{h}^{(l)}$ τις ενεργοποιήσεις του στρώματος l , ο υπολογισμός διατυπώνεται διανυσματικά ως:

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}, \quad (3.4)$$

$$\mathbf{h}^{(l)} = f^{(l)}(\mathbf{z}^{(l)}), \quad (3.5)$$

με $\mathbf{h}^{(0)} = \mathbf{x}$ την είσοδο και $\mathbf{W}^{(l)}$, $\mathbf{b}^{(l)}$ τις παραμέτρους του στρώματος l .

Θεώρημα Καθολικής Προσέγγισης. Η θεωρητική δικαιολόγηση της ισχύος των MLP δίνεται από το *Θεώρημα Καθολικής Προσέγγισης* (Universal Approximation Theorem) [12, 23]: ένα δίκτυο πρόσθιας τροφοδότησης με ένα μόνο κρυφό στρώμα και

επαρκή αριθμό νευρώνων μπορεί να προσεγγίσει με οποιαδήποτε επιθυμητή ακρίβεια κάθε συνεχή συνάρτηση σε ένα συμπαγές υποσύνολο. Το θεώρημα όμως είναι *υπαρξιακό* και δεν εγγυάται ότι η αναγκαία παραμετρική ρύθμιση είναι εφικτή ή ότι θα ανευρεθεί κατά την εκπαίδευση. Στην πράξη, τα *βαθιά* δίκτυα με πολλά κρυφά στρώματα είναι συχνά εκθετικά πιο αποδοτικά ως προς τον αριθμό παραμέτρων από τα αντίστοιχα ρηχά, καθώς αξιοποιούν τη συνθετικότητα της αναπαράστασης.

3.2.2. Συναρτήσεις Ενεργοποίησης

Οι συναρτήσεις ενεργοποίησης εισάγουν τη μη γραμμικότητα που επιτρέπει στα δίκτυα να μοντελοποιούν σύνθετες σχέσεις, χωρίς αυτές, μια στοίβα γραμμικών στρωμάτων θα κατέρρεε σε έναν ισοδύναμο γραμμικό μετασχηματισμό. Παρακάτω παρουσιάζονται οι σημαντικότερες, με έμφαση στην καταλληλότητά τους για το πλαίσιο της εργασίας.

Λογιστική / Σιγμοειδής (Sigmoid).

$$\sigma(x) = \frac{1}{1 + e^{-x}}, \quad \sigma'(x) = \sigma(x)(1 - \sigma(x)). \quad (3.6)$$

Συμπίεζει τις τιμές στο διάστημα $(0, 1)$, γεγονός που την καθιστά κατάλληλη ως έξοδο για δυαδικές πιθανότητες ή ως πύλη (gate) σε αναδρομικά δίκτυα. Μειονέκτημά της είναι ο *κορεσμός* (saturation): για μεγάλες κατά απόλυτη τιμή εισόδους η παράγωγος τείνει στο μηδέν, προκαλώντας εξασθένηση της κλίσης.

Υπερβολική Εφαπτομένη (Tanh).

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}, \quad \tanh'(x) = 1 - \tanh^2(x). \quad (3.7)$$

Συμπίεζει τις τιμές στο $(-1, 1)$ και έχει το πλεονέκτημα ότι είναι *κεντραρισμένη* στο μηδέν, κάτι που διευκολύνει τη βελτιστοποίηση. Στα δίκτυα πολιτικής (policy networks) του PPO με συνεχείς δράσεις, η $\tanh$ χρησιμοποιείται συχνά για να περιορίσει την έξοδο σε ένα φραγμένο διάστημα, αποτρέποντας την εκρηκτική αύξηση της διακύμανσης και των λογαριθμικών πιθανοτήτων που μπορεί να εμφανιστεί με μη φραγμένες ενεργοποιήσεις.

Διορθωμένη Γραμμική Μονάδα (ReLU).

$$\text{ReLU}(x) = \max(0, x). \quad (3.8)$$

Είναι η πιο διαδεδομένη συνάρτηση στη βαθιά μάθηση [39], καθώς μετριάζει δραστικά το πρόβλημα της εξασθένησης της κλίσης (η παράγωγος είναι 1 για θετικές εισόδους) και είναι υπολογιστικά φθηνή. Πιθανό μειονέκτημα είναι το φαινόμενο των «νεκρών νευρώνων»

(dying ReLU), όπου νευρώνες παγιδεύονται μόνιμα στο μηδέν. Η παραλλαγή *Leaky ReLU*, $\text{LReLU}(x) = \max(\alpha x, x)$ με μικρό $\alpha > 0$, αντιμετωπίζει το ζήτημα επιτρέποντας μικρή αρνητική κλίση.

Σιγμοειδής Γραμμική Μονάδα (SiLU / Swish).

$$\text{SiLU}(x) = x \cdot \sigma(x). \quad (3.9)$$

Πρόκειται για μια ομαλή, μη μονότονη συνάρτηση που συνδυάζει τη γραμμική συμπεριφορά της ReLU για μεγάλες θετικές τιμές με την ομαλή διαβάθμιση της σιγμοειδούς [15, 41]. Αποδίδει εξαιρετικά σε βαθιές αρχιτεκτονικές και απαντάται σε σύγχρονα μοντέλα, συμπεριλαμβανομένων αρκετών LLM.

GELU και Softmax. Η *Γκαουσιανή Γραμμική Μονάδα Σφάλματος* (Gaussian Error Linear Unit, GELU), $\text{GELU}(x) = x \Phi(x)$ όπου Φ η αθροιστική συνάρτηση της τυποποιημένης κανονικής κατανομής, αποτελεί την προεπιλεγμένη ενεργοποίηση στους Transformers [21]. Για την παραγωγή κατανομών πιθανότητας στην έξοδο πολυκλασικών προβλημάτων (όπως η ταξινόμηση συναισθήματος σε θετικό/αρνητικό/ουδέτερο) χρησιμοποιείται η *Softmax*:

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}. \quad (3.10)$$

Table 3.1.: Σύνοψη βασικών συναρτήσεων ενεργοποίησης και των ιδιοτήτων τους.

Συνάρτηση	Εύρος	Κεντραρ. στο 0	Τυπική χρήση
Sigmoid	$(0, 1)$	Όχι	πύλες, δυαδική έξοδος
Tanh	$(-1, 1)$	Ναι	RNN/LSTM, policy nets
ReLU	$[0, \infty)$	Όχι	κρυφά στρώματα
Leaky ReLU	$(-\infty, \infty)$	Σχεδόν	κρυφά στρώματα
SiLU/Swish	$\approx (-0.28, \infty)$	Σχεδόν	βαθιά δίκτυα
GELU	$\approx (-0.17, \infty)$	Σχεδόν	Transformers

3.2.3. Συναρτήσεις Σφάλματος / Κόστους

Η συνάρτηση σφάλματος ή κόστους (loss / cost function) ποσοτικοποιεί την απόκλιση των προβλέψεων του μοντέλου από τις επιθυμητές τιμές και αποτελεί το αντικείμενο της βελτιστοποίησης. Η επιλογή της εξαρτάται από τη φύση της εργασίας.

Προβλήματα παλινδρόμησης. Το *Μέσο Τετραγωνικό Σφάλμα* (Mean Squared Error, MSE) είναι η συνηθέστερη επιλογή:

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2. \quad (3.11)$$

Τιμωρεί δυσανάλογα τα μεγάλα σφάλματα, γεγονός που το καθιστά ευαίσθητο σε ακραίες τιμές. Το *Μέσο Απόλυτο Σφάλμα* (Mean Absolute Error, MAE), $\mathcal{L}_{\text{MAE}} = \frac{1}{N} \sum_i |y_i - \hat{y}_i|$, είναι πιο εύρωστο. Η *απώλεια Huber* συνδυάζει τα πλεονεκτήματα και των δύο, συμπεριφερόμενη τετραγωνικά για μικρά σφάλματα και γραμμικά για μεγάλα:

$$\mathcal{L}_\delta(e) = \begin{cases} \frac{1}{2}e^2, & |e| \leq \delta, \\ \delta(|e| - \frac{1}{2}\delta), & |e| > \delta, \end{cases} \quad e = y - \hat{y}. \quad (3.12)$$

Η απώλεια Huber αξιοποιείται συχνά στη συνάρτηση αξίας (value loss) αλγορίθμων RL λόγω της εύρωστης συμπεριφοράς της απέναντι στις θορυβώδεις εκτιμήσεις απόδοσης.

Προβλήματα ταξινόμησης. Για δυαδική ταξινόμηση χρησιμοποιείται η *δυαδική διασταυρούμενη εντροπία* (Binary Cross-Entropy):

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \right]. \quad (3.13)$$

Για K κατηγορίες, η *κατηγορική διασταυρούμενη εντροπία* γενικεύει την ανωτέρω:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} \log \hat{y}_{i,k}. \quad (3.14)$$

Η διασταυρούμενη εντροπία είναι κεντρική στην εκπαίδευση των γλωσσικών μοντέλων, όπου το μοντέλο προβλέπει κατανομή πιθανότητας πάνω σε ένα λεξιλόγιο δεκάδων χιλιάδων διακριτικών (tokens).

3.2.4. Εκπαίδευση Νευρωνικών Δικτύων

Η εκπαίδευση συνίσταται στην εύρεση των παραμέτρων θ που ελαχιστοποιούν τη συνάρτηση κόστους. Αυτό επιτυγχάνεται μέσω επαναληπτικών μεθόδων βελτιστοποίησης βασισμένων στην κλίση (gradient).

Κατάβαση Κλίσης και Οπισθοδιάδοση. Η *Κατάβαση Κλίσης* (Gradient Descent) ενημερώνει επαναληπτικά τις παραμέτρους προς την κατεύθυνση της αρνητικής κλίσης:

$$\theta_{k+1} = \theta_k - \alpha \nabla_{\theta} \mathcal{L}(\theta_k), \quad (3.15)$$

όπου α ο ρυθμός μάθησης (learning rate). Ο υπολογισμός των κλίσεων σε ένα πολυεπίπεδο δίκτυο γίνεται αποδοτικά με τον αλγόριθμο *Οπισθοδιάδοσης* (Backpropagation) [43], ο οποίος εφαρμόζει τον κανόνα της αλυσίδας από το στρώμα εξόδου προς τα πίσω. Ορίζοντας το σφάλμα του στρώματος l ως $\delta^{(l)} = \partial \mathcal{L} / \partial \mathbf{z}^{(l)}$, ισχύει η αναδρομή:

$$\delta^{(l)} = (\mathbf{W}^{(l+1)})^{\top} \delta^{(l+1)} \odot f'^{(l)}(\mathbf{z}^{(l)}), \quad (3.16)$$

όπου $\odot$ συμβολίζει το γινόμενο Hadamard.

Στοχαστική και κατά παρτίδες κατάβαση. Η χρήση ολόκληρου του συνόλου δεδομένων σε κάθε βήμα είναι υπολογιστικά απαγορευτική. Στην πράξη χρησιμοποιείται η *Στοχαστική Κατάβαση Κλίσης* (Stochastic Gradient Descent, SGD) ή, συνηθέστερα, η *κατά μικρο-παρτίδες* (mini-batch) εκδοχή, όπου η κλίση εκτιμάται σε μικρά τυχαία υποσύνολα. Ο θόρυβος της εκτίμησης αυτής λειτουργεί συχνά ευεργετικά, βοηθώντας τη διαφυγή από ρηχά τοπικά ελάχιστα.

Ο βελτιστοποιητής Adam. Ο αλγόριθμος Adam (Adaptive Moment Estimation) [29] προσαρμόζει τον ρυθμό μάθησης ξεχωριστά για κάθε παράμετρο, διατηρώντας εκτιμήσεις της πρώτης και της δεύτερης ροπής των κλίσεων. Έστω $g_t = \nabla_{\theta} \mathcal{L}(\theta_t)$. Υπολογίζονται η ορμή (πρώτη ροπή) και ο κυλιόμενος μέσος των τετραγώνων (δεύτερη ροπή):

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (3.17)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2. \quad (3.18)$$

Μετά τη διόρθωση μεροληψίας, $\hat{m}_t = m_t / (1 - \beta_1^t)$ και $\hat{v}_t = v_t / (1 - \beta_2^t)$, οι παράμετροι ενημερώνονται ως:

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t. \quad (3.19)$$

Η αυξημένη ευστάθεια του Adam απέναντι σε θορυβώδεις κλίσεις τον καθιστά προεπιλογή στη DRL, όπου οι εκτιμήσεις της κλίσης είναι εγγενώς υψηλής διακύμανσης.

Κανονικοποίηση και αντιμετώπιση της υπερπροσαρμογής. Για τη βελτίωση της γενίκευσης εφαρμόζονται διάφορες τεχνικές κανονικοποίησης (regularization):

- **Κανονικοποίηση L_2** (weight decay): προσθήκη όρου $\lambda \|\theta\|_2^2$ στη συνάρτηση κόστους, που αποθαρρύνει μεγάλα βάρη. Η L_1 προωθεί αραιότητα.
- **Dropout** [49]: τυχαία απενεργοποίηση νευρώνων κατά την εκπαίδευση, που λειτουργεί ως συγκερασμός (ensemble) και αποτρέπει τη συν-προσαρμογή.
- **Κανονικοποίηση παρτίδας** (Batch Normalization) [25]: κανονικοποίηση των ενεργοποιήσεων εντός κάθε παρτίδας, που σταθεροποιεί και επιταχύνει την εκπαίδευση.
- **Πρώιμη διακοπή** (early stopping): τερματισμός της εκπαίδευσης όταν η απόδοση σε σύνολο επικύρωσης παύει να βελτιώνεται.

Στο χρηματοοικονομικό πλαίσιο, η κανονικοποίηση είναι κρίσιμη, διότι ο υψηλός θόρυβος των αγορών καθιστά εξαιρετικά εύκολη την υπερπροσαρμογή σε ψευδο-μοτίβα του ιστορικού δείγματος.

3.2.5. Αναδρομικά Δίκτυα και Δίκτυα Μακράς Βραχύχρονης Μνήμης (LSTM)

Αναδρομικά Νευρωνικά Δίκτυα. Τα δίκτυα πρόσθιας τροφοδότησης υποθέτουν ανεξαρτησία μεταξύ των δειγμάτων, γεγονός ακατάλληλο για δεδομένα ακολουθιακής/χρονικής φύσης. Τα *Αναδρομικά Νευρωνικά Δίκτυα* (Recurrent Neural Networks, RNNs) εισάγουν μια κρυφή κατάσταση $\mathbf{h}_t$ που λειτουργεί ως μνήμη, ανανεωνόμενη σε κάθε βήμα:

$$\mathbf{h}_t = f(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h). \quad (3.20)$$

Ωστόσο, η εκπαίδευση μέσω *Οπισθοδιάδοσης στον Χρόνο* (Backpropagation Through Time) πάσχει από το πρόβλημα της *εξασθένισης ή έκρηξης της κλίσης* (vanishing / exploding gradient) [6]: κατά την οπισθοδιάδοση σε πολλά βήματα, οι κλίσεις πολλαπλασιάζονται επανειλημμένα, τείνοντας εκθετικά στο μηδέν ή στο άπειρο. Αυτό εμποδίζει τα κλασικά RNN από το να μάθουν μακροπρόθεσμες εξαρτήσεις.

Η αρχιτεκτονική LSTM. Τα *Δίκτυα Μακράς Βραχύχρονης Μνήμης* (Long Short-Term Memory, LSTM) [22] αντιμετωπίζουν το πρόβλημα εισάγοντας μια *κατάσταση κελιού* (cell state) $\mathbf{C}_t$, η οποία λειτουργεί ως «αρτηρία» πληροφορίας με ελάχιστες γραμμικές αλληλεπιδράσεις, ελεγχόμενη από τρεις *πύλες* (gates).

Η **Πύλη Λήθης** (Forget Gate) καθορίζει ποιο μέρος της προηγούμενης μνήμης διατηρείται:

$$\mathbf{f}_t = \sigma(\mathbf{W}_{xf}\mathbf{x}_t + \mathbf{W}_{hf}\mathbf{h}_{t-1} + \mathbf{b}_f). \quad (3.21)$$

Η **Πύλη Εισόδου** (Input Gate) επιλέγει ποια νέα πληροφορία θα εγγραφεί:

$$\mathbf{i}_t = \sigma(\mathbf{W}_{xi}\mathbf{x}_t + \mathbf{W}_{hi}\mathbf{h}_{t-1} + \mathbf{b}_i). \quad (3.22)$$

Η υποψήφια νέα κατάσταση υπολογίζεται μέσω της υπερβολικής εφαπτομένης:

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_{xc}\mathbf{x}_t + \mathbf{W}_{hc}\mathbf{h}_{t-1} + \mathbf{b}_c). \quad (3.23)$$

Η κατάσταση του κελιού ανανεώνεται συνδυάζοντας παλαιά και νέα πληροφορία:

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t. \quad (3.24)$$

Τέλος, η **Πύλη Εξόδου** (Output Gate) καθορίζει την κρυφή κατάσταση εξόδου:

$$\mathbf{o}_t = \sigma(\mathbf{W}_{xo}\mathbf{x}_t + \mathbf{W}_{ho}\mathbf{h}_{t-1} + \mathbf{b}_o), \quad (3.25)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t). \quad (3.26)$$

Η αθροιστική (αντί πολλαπλασιαστικής) φύση της Εξίσωσης (3.24) επιτρέπει στις κλίσεις να διαδίδονται σχεδόν αναλλοίωτες σε μεγάλα χρονικά διαστήματα, λύνοντας πρακτικά το πρόβλημα της εξασθένησης. Μια απλούστερη παραλλαγή με δύο πύλες είναι η *Πυλωτή Αναδρομική Μονάδα* (Gated Recurrent Unit, GRU) [11].

Σημασία για την παρούσα εργασία. Τα LSTM είναι ιδιαίτερος κατάλληλα για τις χρηματοοικονομικές αγορές, οι οποίες, όπως θα τεκμηριωθεί στην Ενότητα 3.3, αποτελούν μερικώς παρατηρήσιμα περιβάλλοντα. Η κρυφή κατάσταση του δικτύου μπορεί να λειτουργήσει ως συμπυκνωμένη εκτίμηση του μη ορατού καθεστώτος της αγοράς, ενσωματώνοντας πληροφορία από προηγούμενα χρονικά βήματα. Στον προτεινόμενο πράκτορα, το LSTM λαμβάνει ως είσοδο, σε κάθε χρονικό βήμα, την τρέχουσα παρατήρηση της αγοράς (τεχνικοί δείκτες, συνθέσεις χαρτοφυλακίου, σήματα συναισθήματος) και παράγει ένα διάνυσμα κρυφής κατάστασης σταθερού μεγέθους, το οποίο συνοψίζει το σχετικό χρονικό πλαίσιο. Αυτό το διάνυσμα τροφοδοτείται στη συνέχεια παράλληλα σε δύο ξεχωριστές κεφαλές MLP: στον Actor, ο οποίος εξάγει την κατανομή δράσεων (πολιτική), και στον Critic, ο οποίος εκτιμά τη συνάρτηση αξίας κατάστασης. Με τον τρόπο αυτόν, η αρχιτεκτονική PPO-LSTM αξιοποιεί τη μνήμη ακολουθιών του LSTM για τη λήψη πολιτικής αποφάσεων υπό μερική παρατηρησιμότητα.

3.3. Βαθιά Ενισχυτική Μάθηση

Η Βαθιά Ενισχυτική Μάθηση (Deep Reinforcement Learning, DRL) προκύπτει από τον συνδυασμό του πλαισίου της Ενισχυτικής Μάθησης (Ενότητα 3.1.3) με τη δύναμη αναπα-

ράστασης των βαθιών νευρωνικών δικτύων. Τα δίκτυα χρησιμοποιούνται ως *προσεγγιστές συναρτήσεων* (function approximators) για την *πολιτική* $\pi_\theta(a | s)$ (η απεικόνιση από καταστάσεις σε κατανομές δράσεων, που ορίζεται διεξοδικά στην Ενότητα 3.3.1) ή/και τη *συνάρτηση αξίας* $V^\pi(s)$ (που εκφράζει την αναμενόμενη μακροπρόθεσμη ανταμοιβή, η οποία αναπτύσσεται στην Ενότητα 3.3.2), επιτρέποντας την αντιμετώπιση προβλημάτων με συνεχείς ή υψηλής διάστασης χώρους καταστάσεων, για τους οποίους οι κλασικές πινακοποιημένες (tabular) μέθοδοι είναι ανεφάρμοστες.

3.3.1. Μαρκοβιανές Διαδικασίες Απόφασης (MDP)

Το μαθηματικό θεμέλιο της Ενισχυτικής Μάθησης είναι η *Μαρκοβιανή Διαδικασία Απόφασης* (Markov Decision Process, MDP) [50]. Μια MDP ορίζεται από την πλειάδα $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$, όπου:

- $\mathcal{S}$ είναι το σύνολο των καταστάσεων (state space),
- $\mathcal{A}$ είναι το σύνολο των δράσεων (action space),
- $P(s' | s, a)$ είναι η συνάρτηση μετάβασης, δηλαδή η πιθανότητα μετάβασης στην s' δεδομένης της κατάστασης s και της δράσης a ,
- $R(s, a)$ είναι η συνάρτηση ανταμοιβής,
- $\gamma \in (0, 1]$ είναι ο συντελεστής προεξόφλησης (discount factor).

Κεντρική είναι η *Μαρκοβιανή ιδιότητα*: η κατανομή της επόμενης κατάστασης εξαρτάται *μόνο* από την τρέχουσα κατάσταση και δράση, και όχι από ολόκληρο το ιστορικό παρελθόν:

$$P(s_{t+1} | s_t, a_t, s_{t-1}, a_{t-1}, \dots) = P(s_{t+1} | s_t, a_t). \quad (3.27)$$

Ο πράκτορας ενεργεί σύμφωνα με μια *πολιτική* $\pi(a | s)$, μια (εν γένει στοχαστική) απεικόνιση από καταστάσεις σε κατανομές δράσεων. Στόχος είναι η μεγιστοποίηση της αναμενόμενης προεξοφλημένης σωρευτικής ανταμοιβής, γνωστής ως *απόδοση* (return):

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}. \quad (3.28)$$

Ο συντελεστής γ ρυθμίζει τη βαρύτητα μελλοντικών έναντι άμεσων ανταμοιβών: τιμές κοντά στο 1 ευνοούν τη μακροπρόθεσμη σκέψη, ενώ μικρότερες τιμές προσδίδουν «μυωπικό» χαρακτήρα στον πράκτορα.

3.3.2. Εξισώσεις Bellman

Για την αξιολόγηση μιας πολιτικής ορίζονται δύο θεμελιώδεις συναρτήσεις αξίας. Η *Συνάρτηση Αξίας Κατάστασης* (State-Value Function) εκφράζει την αναμενόμενη απόδοση εκκινώντας από την κατάσταση s και ακολουθώντας την π :

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid s_t = s] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \mid s_t = s \right]. \quad (3.29)$$

Η *Συνάρτηση Αξίας Δράσης/Κατάστασης* (Action-Value ή Q-function) αξιολογεί την επιλογή της δράσης a στην s :

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a]. \quad (3.30)$$

Η αναδρομική φύση των συναρτήσεων αυτών αποτυπώνεται στις *εξισώσεις Bellman* [5]. Η *εξίσωση προσδοκίας Bellman* (Bellman expectation equation) για την V^π είναι:

$$V^\pi(s) = \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a) [R(s, a) + \gamma V^\pi(s')]. \quad (3.31)$$

Η βέλτιστη πολιτική π^* ικανοποιεί την *εξίσωση βελτιστότητας Bellman* (Bellman optimality equation):

$$V^*(s) = \max_a \sum_{s'} P(s' \mid s, a) [R(s, a) + \gamma V^*(s')], \quad (3.32)$$

$$Q^*(s, a) = \sum_{s'} P(s' \mid s, a) \left[R(s, a) + \gamma \max_{a'} Q^*(s', a') \right]. \quad (3.33)$$

Οι εξισώσεις αυτές αποτελούν τη βάση τόσο των μεθόδων δυναμικού προγραμματισμού όσο και των σύγχρονων αλγορίθμων DRL, οι οποίοι επιδιώκουν να εκτιμήσουν τις V^* ή Q^* μέσω δειγματοληψίας και προσέγγισης συναρτήσεων.

3.3.3. Μερικώς Παρατηρήσιμη Μαρκοβιανή Διαδικασία Απόφασης (POMDP)

Η υπόθεση της πλήρους παρατηρησιμότητας της κατάστασης σπανίως ισχύει σε πραγματικά συστήματα. Στις χρηματοοικονομικές αγορές, ειδικότερα, ο πράκτορας δεν έχει πρόσβαση στο πραγματικό υποκείμενο *καθεστώς* (regime) της αγοράς, τις προθέσεις των υπόλοιπων συμμετεχόντων, τη ρευστότητα εκτός βιβλίου εντολών, τη μελλοντική ροή ειδήσεων. Παρατηρεί μόνο ένα θορυβώδες, μερικό «αποτύπωμα» αυτού του καθεστώτος.

Το κατάλληλο πλαίσιο είναι η *Μερικώς Παρατηρήσιμη Μαρκοβιανή Διαδικασία Απόφασης* (Partially Observable Markov Decision Process, POMDP) [28], που ορίζεται από την πλειάδα $(\mathcal{S}, \mathcal{A}, P, R, \Omega, O, \gamma)$. Στα στοιχεία της MDP προστίθενται:

- Ω , το σύνολο των δυνατών παρατηρήσεων (observations),
- $O(o | s', a)$, το μοντέλο παρατήρησης που δίνει την πιθανότητα να ληφθεί η παρατήρηση o μετά τη μετάβαση στην s' .

Επειδή η αληθής κατάσταση s είναι κρυφή, ο πράκτορας διατηρεί μια κατάσταση πεποίθησης (belief state) $b(s)$, δηλαδή μια κατανομή πιθανότητας πάνω στις καταστάσεις, την οποία ανανεώνει με βάση κάθε νέα παρατήρηση κατά Bayes:

$$b'(s') = \eta O(o | s', a) \sum_s P(s' | s, a) b(s), \quad (3.34)$$

όπου η είναι σταθερά κανονικοποίησης. Θεωρητικά, μια POMDP μπορεί να αναχθεί σε μια ισοδύναμη MDP πάνω στον χώρο πεποιθήσεων, δηλαδή στον χώρο όλων των πιθανών κατανομών πιθανότητας πάνω στις κρυφές καταστάσεις $s \in \mathcal{S}$. Ωστόσο, η ρητή βελτιστοποίηση σε αυτόν τον χώρο είναι υπολογιστικά αδύνατη στην πράξη, καθώς ο χώρος είναι συνεχής και υψηλής διάστασης, και η ανανέωσή του κατά Bayes σε κάθε βήμα απαιτεί διατήρηση και ενημέρωση μιας πλήρους κατανομής πάνω σε όλες τις δυνατές καταστάσεις. Αυτή η υπολογιστική αδυναμία αποτελεί το κεντρικό κίνητρο για την υιοθέτηση προσεγγιστικών μεθόδων, όπως η χρήση αναδρομικών νευρωνικών δικτύων ως έμμεσων κωδικοποιητών πεποίθησης, που αναλύεται στην επόμενη υποενότητα.

3.3.4. Πράκτορες που Λαμβάνουν Υπόψη τη Μερική Παρατηρησιμότητα

Ο ρητός υπολογισμός και η ανανέωση της κατάστασης πεποίθησης μέσω της Εξίσωσης (3.34) είναι εν γένει υπολογιστικά δυσεπίλυτος σε ρεαλιστικά προβλήματα. Η σύγχρονη DRL προσέγγιση παρακάμπτει το πρόβλημα *μαθαίνοντας* μια συμπυκνωμένη αναπαράσταση της πεποίθησης απευθείας από την ακολουθία παρατηρήσεων, αξιοποιώντας αναδρομικά δίκτυα.

Συγκεκριμένα, αντικαθιστώντας το στρώμα εξόδου ενός Deep Q-Network με ένα στρώμα LSTM, προκύπτει το *Deep Recurrent Q-Network* (DRQN) [20], το οποίο αποδεικνύεται σημαντικά πιο εύρωστο σε συνθήκες μερικής παρατηρησιμότητας. Η κρυφή κατάσταση $\mathbf{h}_t$ του αναδρομικού δικτύου λειτουργεί ως μια μαθημένη, πεπερασμένης διάστασης εκτίμηση της κατάστασης πεποίθησης, δηλαδή ενσωματώνει το σχετικό ιστορικό παρατηρήσεων σε ένα διάνυσμα σταθερού μεγέθους, χωρίς να απαιτείται ρητή γνώση του μοντέλου παρατήρησης.

Αυτή ακριβώς είναι η αρχιτεκτονική επιλογή της παρούσας εργασίας, ο πράκτορας PPO-LSTM χρησιμοποιεί ένα αναδρομικό στρώμα ώστε να αντιμετωπίσει το χρηματοοικονομικό περιβάλλον ως POMDP. Η κρυφή κατάσταση συμπυκνώνει το πρόσφατο ιστορικό τιμών, τεχνικών δεικτών και του σήματος συναισθήματος, παρέχοντας στον πράκτορα μια λειτουργική εκτίμηση του μη ορατού καθεστώτος της αγοράς.

3.3.5. Περιορισμένες Μαρκοβιανές Διαδικασίες Απόφασης (CMDP)

Σε πολλά πραγματικά προβλήματα, και ιδιαιτέρως στις χρηματοοικονομικές συναλλαγές, η απλή μεγιστοποίηση της ανταμοιβής δεν επαρκεί, είναι αναγκαία η τήρηση *περιορισμών* (π.χ. μέγιστη ανεκτή πτώση κεφαλαίου, όρια έκθεσης, μέγιστη μόχλευση). Η *Περιορισμένη Μαρκοβιανή Διαδικασία Απόφασης* (Constrained Markov Decision Process, CMDP) [1] επεκτείνει την MDP εισάγοντας μία ή περισσότερες *συναρτήσεις κόστους* $C_i(s, a)$ με αντίστοιχα όρια d_i . Το πρόβλημα βελτιστοποίησης γίνεται:

$$\max_{\pi} \mathbb{E}_{\pi} \left[\sum_t \gamma^t r_t \right] \quad \text{υπό τον περιορισμό} \quad \mathbb{E}_{\pi} \left[\sum_t \gamma^t C_i(s_t, a_t) \right] \leq d_i, \quad \forall i. \quad (3.35)$$

Η συνηθέστερη προσέγγιση επίλυσης είναι η *χαλάρωση Lagrange*, όπου εισάγονται πολλαπλασιαστές $\lambda_i \geq 0$ και βελτιστοποιείται η συνάρτηση Lagrange:

$$\mathcal{L}(\pi, \lambda) = \mathbb{E}_{\pi} \left[\sum_t \gamma^t r_t \right] - \sum_i \lambda_i \left(\mathbb{E}_{\pi} \left[\sum_t \gamma^t C_i \right] - d_i \right). \quad (3.36)$$

Στο πλαίσιο αυτής της εργασίας, η οπτική των CMDP παρέχει το εννοιολογικό υπόβαθρο για τη μοντελοποίηση της διαχείρισης κινδύνου. Αντί ο κίνδυνος να ενσωματώνεται αποκλειστικά ως ποινή στην ανταμοιβή, μπορεί να αντιμετωπιστεί ως ρητός περιορισμός, οδηγώντας σε πιο ερμηνεύσιμη και ελεγχόμενη συμπεριφορά.

3.3.6. Μέθοδοι Βαθιάς Ενισχυτικής Μάθησης

Οι αλγόριθμοι DRL κατατάσσονται παραδοσιακά σε τρεις μεγάλες οικογένειες (Πίνακας 3.2).

Μέθοδοι βασισμένες στην αξία. Οι μέθοδοι αυτές (value-based) εκτιμούν τη συνάρτηση Q^* και εξάγουν την πολιτική επιλέγοντας τη δράση με τη μέγιστη τιμή. Ο αντιπροσωπευτικός αλγόριθμος είναι το *Deep Q-Network* (DQN) [37], που εισήγαγε δύο κρίσιμες καινοτομίες για τη σταθεροποίηση της εκπαίδευσης: την *επανάληψη εμπειρίας* (experience replay) και ένα *δίκτυο-στόχο* (target network). Το DQN ελαχιστοποιεί το σφάλμα χρονικής διαφοράς:

$$\mathcal{L}(\theta) = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q_{\theta^-}(s', a') - Q_{\theta}(s, a) \right)^2 \right], \quad (3.37)$$

όπου θ^- οι παράμετροι του δικτύου-στόχου. Οι μέθοδοι αξίας περιορίζονται κυρίως σε διακριτούς χώρους δράσεων.

Μέθοδοι βασισμένες στην πολιτική. Οι μέθοδοι αυτές (policy-based) βελτιστοποιούν απευθείας μια παραμετροποιημένη πολιτική π_θ . Το θεμελιώδες *Θεώρημα Κλίσης Πολιτικής* (Policy Gradient Theorem) δίνει την κατεύθυνση ανόδου:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} \left[\nabla_\theta \log \pi_\theta(a | s) Q^\pi(s, a) \right]. \quad (3.38)$$

Ο αλγόριθμος *REINFORCE* [54] αποτελεί την απλούστερη υλοποίηση, αντικαθιστώντας το Q^π με τη δειγματοληπτική απόδοση G_t . Πλεονέκτημα είναι η φυσική διαχείριση συνεχών χώρων δράσεων, μειονέκτημα η υψηλή διακύμανση των εκτιμήσεων.

Μέθοδοι Actor/Critic Οι αρχιτεκτονικές *Actor/Critic* συνδυάζουν τα δύο παραπάνω παραδείγματα (Σχήμα 3.3). Ο *Actor* $\pi_\theta(a | s)$ επιλέγει δράσεις, ενώ ο *Critic* $V_\phi(s)$ εκτιμά τη συνάρτηση αξίας και αξιολογεί τις επιλογές του Actor. Η αξιολόγηση γίνεται μέσω του *Πλεονεκτήματος* (Advantage):

$$A_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t), \quad (3.39)$$

που μετρά πόσο καλύτερη ή χειρότερη ήταν μια δράση σε σχέση με τη «μέση» αναμενόμενη συμπεριφορά. Η χρήση του πλεονεκτήματος μειώνει σημαντικά τη διακύμανση σε σχέση με το REINFORCE. Αντιπροσωπευτικοί αλγόριθμοι είναι οι A2C/A3C [36]. Μια εκλεπτυσμένη, χαμηλότερης διακύμανσης εκτίμηση δίνεται από το *Γενικευμένο Πλεονέκτημα* (Generalized Advantage Estimation, GAE) [45]:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}, \quad \delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t), \quad (3.40)$$

όπου η παράμετρος $\lambda \in [0, 1]$ ρυθμίζει την αντιστάθμιση μεροληψίας/διακύμανσης.




Figure 3.3.: Αρχιτεκτονική Actor/Critic. Ο Critic εκτιμά την αξία της κατάστασης και τροφοδοτεί τον Actor με το σήμα πλεονεκτήματος A_t , το οποίο κατευθύνει την ενημέρωση της πολιτικής.

Table 3.2.: Ταξινόμηση βασικών οικογενειών αλγορίθμων Ενισχυτικής Μάθησης.

Οικογένεια	Τι μαθαίνει	Παραδείγματα
Βασισμένη στην αξία	$Q(s, a)$	Q-learning, DQN
Βασισμένη στην πολιτική	$\pi_\theta(a s)$	REINFORCE
Actor/Critic	π_θ & V_ϕ	A2C, A3C, PPO, SAC

3.3.7. Αλγόριθμος Proximal Policy Optimization (PPO)

Βασικό πρόβλημα των μεθόδων κλίσης πολιτικής είναι ότι μεγάλα βήματα ενημέρωσης μπορούν να καταστρέψουν μια ήδη καλή πολιτική, οδηγώντας σε κατάρρευση της απόδοσης. Ο αλγόριθμος *Trust Region Policy Optimization* (TRPO) [44] αντιμετώπισε το ζήτημα περιορίζοντας την απόκλιση KL (Kullback-Leibler divergence, $D_{KL}(\pi_{old} \parallel \pi_\theta) = \mathbb{E}_{a \sim \pi_{old}} \left[\log \frac{\pi_{old}(a|s)}{\pi_\theta(a|s)} \right]$), η οποία μετρά πόσο διαφέρει η νέα κατανομή πολιτικής από την παλαιά, μεταξύ διαδοχικών ενημερώσεων, με κόστος όμως σημαντική υπολογιστική πολυπλοκότητα.

Ο αλγόριθμος *Proximal Policy Optimization* (PPO) [46] επιτυγχάνει παρόμοια ευστάθεια με δραστικά απλούστερο τρόπο, χρησιμοποιώντας έναν μηχανισμό *αποκοπής* (clipping). Είναι σήμερα ένας από τους δημοφιλέστερους αλγορίθμους DRL και αποτελεί τον πυρήνα του πράκτορα της παρούσας εργασίας, λόγω της ευρωστίας του σε θορυβώδη, μη στάσιμα περιβάλλοντα.

Η συνολική αντικειμενική συνάρτηση του PPO είναι μια *σύνθετη απώλεια* που συνενώνει τρεις όρους.

1. Αποκομμένη υποκατάστατη απώλεια (Actor). Έστω ο λόγος πιθανοτήτων μεταξύ νέας και παλαιάς πολιτικής:

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{old}}(a_t | s_t)}. \quad (3.41)$$

Η απώλεια του Actor ορίζεται ως:

$$\mathcal{L}^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (3.42)$$

όπου ϵ (τυπικά 0.1–0.2) είναι η υπερπαραμέτρος αποκοπής. Ο όρος $\min$ μαζί με την αποκοπή αποτρέπει την πολιτική από υπερβολικά μεγάλες μεταβολές σε ένα μόνο βήμα ενημέρωσης, υλοποιώντας μια «μαλακή» περιοχή εμπιστοσύνης χωρίς ρητό περιορισμό.

2. Απώλεια αξίας (Critic). Η εκπαίδευση του Critic ελαχιστοποιεί το τετραγωνικό σφάλμα μεταξύ της εκτίμησης αξίας και των εμπειρικών αποδόσεων R_t :

$$\mathcal{L}^{VF}(\phi) = \mathbb{E}_t \left[\left(V_\phi(s_t) - R_t \right)^2 \right]. \quad (3.43)$$

3. Όρος εντροπίας. Για τη διασφάλιση επαρκούς εξερεύνησης προστίθεται ένας όρος που ενθαρρύνει στοχαστικές πολιτικές, μέσω της εντροπίας Shannon H της κατανομής δράσεων:

$$\mathcal{L}^{ENT}(\theta) = \mathbb{E}_t \left[H(\pi_\theta(\cdot | s_t)) \right]. \quad (3.44)$$

Συνολική αντικειμενική συνάρτηση. Η τελική συνάρτηση που μεγιστοποιείται είναι ο γραμμικός συνδυασμός των τριών όρων:

$$\mathcal{L}^{\text{total}} = \mathbb{E}_t \left[\mathcal{L}^{\text{CLIP}}(\theta) - c_1 \mathcal{L}^{\text{VF}}(\phi) + c_2 \mathcal{L}^{\text{ENT}}(\theta) \right], \quad (3.45)$$

όπου c_1, c_2 είναι συντελεστές στάθμισης. Στην παρούσα εργασία, ο PPO συνδυάζεται με αναδρομικό δίκτυο LSTM (PPO-LSTM): η κρυφή κατάσταση τροφοδοτεί τόσο τον Actor όσο και τον Critic, επιτρέποντας τη λήψη αποφάσεων με βάση το ιστορικό, όπως απαιτεί το μερικώς παρατηρήσιμο χρηματοοικονομικό περιβάλλον.

3.4. Μεγάλα Γλωσσικά Μοντέλα και Ανάλυση Συναισθήματος

Η αποκλειστική χρήση αριθμητικών δεδομένων αγοράς αγνοεί έναν τεράστιο όγκο πληροφορίας που περιέχεται σε κείμενα: ειδήσεις, οικονομικές αναφορές, αναρτήσεις σε μέσα κοινωνικής δικτύωσης. Η ενότητα αυτή παρουσιάζει τα Μεγάλα Γλωσσικά Μοντέλα (LLM) και τις τεχνικές ανάλυσης συναισθήματος.

3.4.1. Επεξεργασία Φυσικής Γλώσσας και η Αρχιτεκτονική Transformer

Η Επεξεργασία Φυσικής Γλώσσας (Natural Language Processing, NLP) αποσκοπεί στην υπολογιστική κατανόηση και παραγωγή ανθρώπινης γλώσσας. Οι πρώιμες προσεγγίσεις βασίστηκαν σε διανυσματικές αναπαραστάσεις λέξεων (word embeddings), που απεικονίζουν λέξεις σε έναν συνεχή χώρο όπου η σημασιολογική εγγύτητα αντιστοιχεί σε γεωμετρική εγγύτητα. Ωστόσο, οι αναπαραστάσεις αυτές ήταν στατικές, αδυνατώντας να αποτυπώσουν την εξάρτηση της σημασίας από τα συμφραζόμενα.

Η καθοριστική τομή ήρθε με την αρχιτεκτονική *Transformer* και τον *Μηχανισμό Αυτο-Προσοχής* (Self-Attention) [53]. Σε αντίθεση με τα αναδρομικά δίκτυα που επεξεργάζονται την ακολουθία διαδοχικά, η προσοχή επιτρέπει σε κάθε διακριτικό (token) να «εστιάζει» ταυτόχρονα σε όλα τα υπόλοιπα, υπολογίζοντας σταθμισμένους συσχετισμούς. Δεδομένων των πινάκων Ερωτημάτων $\mathbf{Q}$, Κλειδιών $\mathbf{K}$ και Τιμών $\mathbf{V}$, η προσοχή ορίζεται ως:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V}, \quad (3.46)$$

όπου d_k είναι η διάσταση των κλειδιών και ο παράγοντας $\sqrt{d_k}$ σταθεροποιεί αριθμητικά τις κλίσεις. Ο μηχανισμός επεκτείνεται σε *πολλαπλές κεφαλές* (multi-head attention), που επιτρέπουν την ταυτόχρονη μάθηση διαφορετικών τύπων σχέσεων. Η παραλληλοποίηση

φύση των Transformers κατέστησε εφικτή την κλιμάκωση σε μοντέλα δισεκατομμυρίων παραμέτρων.

Θεωρητική δικαιολόγηση και επιλογή για χρηματοοικονομικό κείμενο.

Η υπεροχή των Transformers έναντι των κλασικών αναδρομικών δικτύων στη μοντελοποίηση κειμένου ερείδεται σε δύο θεωρητικές ιδιότητες: αφενός, ο μηχανισμός αυτο-προσοχής παρέχει άμεση σύνδεση μεταξύ κάθε ζεύγους διακριτικών, ανεξαρτήτως απόστασης στην ακολουθία, αποφεύγοντας το πρόβλημα της εξασθένησης κλίσης που πλήττει τα RNN. Αφετέρου, η παραλληλοποίηση του υπολογισμού επιτρέπει αποδοτική εκπαίδευση σε τεράστια σώματα κειμένων, από τα οποία το μοντέλο αναδύει ισχυρές αναπαραστάσεις συμφραζόμενων. Αυτές οι ιδιότητες είναι ιδιαιτέρως σχετικές για το χρηματοοικονομικό πεδίο: η σημαντικότητα μιας ειδησεογραφικής φράσης συχνά εξαρτάται από το ευρύτερο πλαίσιο της (π.χ. η λέξη «αθέτηση» φέρει διαφορετικό συναισθηματικό φορτίο σε κειμενικό περιβάλλον που αφορά κρατικό χρέος έναντι τεχνολογικής ορολογίας), κάτι που τα στατικά λεξικά ή οι αναπαραστάσεις χωρίς συμφραζόμενα δεν μπορούν να αποτυπώσουν.

Περιορισμοί και γνωστά αδύναμα σημεία. Παρά την εμπειρική επιτυχία τους, οι Transformers εμφανίζουν ορισμένους γνωστούς περιορισμούς που είναι συναφείς για την εφαρμογή τους σε χρηματοοικονομικά κείμενα. Πρώτον, η πολυπλοκότητα της αυτο-προσοχής κλιμακώνεται τετραγωνικά ως προς το μήκος της ακολουθίας, γεγονός που περιορίζει την άμεση επεξεργασία πολύ μακρών εγγράφων (π.χ. εκτενείς εκθέσεις αποτελεσμάτων). Δεύτερον, η προεκπαίδευση σε γενικά κείμενα δεν εγγυάται επαρκή κατανόηση της εξειδικευμένης ορολογίας των κρυπτονομισμάτων, η οποία εξελίσσεται ταχύτατα και περιλαμβάνει ιδιαίτερες εκφράσεις της κοινότητας (π.χ. «FOMO», «rug pull», «whale alert»). Αυτός ακριβώς ο περιορισμός δικαιολογεί τη μικρο-προσαρμογή (fine-tuning) του LLM σε στοχευμένα δεδομένα χρηματοοικονομικής ειδησεογραφίας, η οποία αναλύεται στην Ενότητα 3.4.5.

3.4.2. Μεγάλα Γλωσσικά Μοντέλα (LLMs)

Τα *Μεγάλα Γλωσσικά Μοντέλα* (Large Language Models, LLMs) είναι μοντέλα βασισμένα σε Transformers με εκατομμύρια έως δισεκατομμύρια παραμέτρους, εκπαιδευμένα σε τεράστια σώματα κειμένων. Η εκπαίδευσή τους ακολουθεί τυπικά δύο φάσεις:

1. **Προεκπαίδευση** (pre-training): αυτο-επιβλεπόμενη μάθηση σε γενικά κείμενα, με στόχο την πρόβλεψη του επόμενου διακριτικού (autoregressive language modeling, π.χ. μοντέλα τύπου GPT [10]) ή την ανακατασκευή αποκρυμμένων διακριτικών (masked language modeling, π.χ. BERT [14]).

2. **Μικρο-προσαρμογή** (fine-tuning): εξειδίκευση του προεκπαιδευμένου μοντέλου σε μια συγκεκριμένη εργασία ή πεδίο με μικρότερο, στοχευμένο σύνολο δεδομένων.

Τα LLMs επιδεικνύουν αξιοσημείωτες ικανότητες *μηδενικής* (zero-shot) και *ολίγων δειγμάτων* (few-shot) μάθησης, καθώς και αναδυόμενη συλλογιστική ικανότητα. Στο χρηματοοικονομικό πεδίο, μπορούν να αναλύσουν τη σημασιολογία ειδήσεων και αναρτήσεων, εξάγοντας δείκτες επενδυτικής ψυχολογίας.

3.4.3. Ανάλυση Συναισθήματος

Η *Ανάλυση Συναισθήματος* (Sentiment Analysis) είναι η εργασία NLP που στοχεύει στον προσδιορισμό της συναισθηματικής χροιάς ενός κειμένου, τυπικά σε μια κλίμακα θετικό/ουδέτερο/αρνητικό ή σε μια συνεχή βαθμολογία. Η ιστορική της εξέλιξη διακρίνεται σε τρεις γενιές:

1. **Μέθοδοι λεξικού** (lexicon-based): βασίζονται σε προκαθορισμένα λεξικά λέξεων με συναισθηματικά φορτία. Στα χρηματοοικονομικά, σταθμός υπήρξε το λεξικό Loughran/McDonald [34], που προσαρμοσε την ανάλυση στην ιδιαίτερη ορολογία των οικονομικών αναφορών. Αδυναμία τους η αδυναμία σύλληψης συμφραζομένων, άρνησης και σαρκασμού.
2. **Μέθοδοι μηχανικής μάθησης / Transformers**: μοντέλα όπως το FinBERT [2], ένα BERT προσαρμοσμένο σε χρηματοοικονομικά κείμενα, παρέχουν αναπαραστάσεις ευαίσθητες στα συμφραζόμενα, βελτιώνοντας δραστικά την ακρίβεια.
3. **Μέθοδοι βασισμένες σε LLM**: αναλύονται στην επόμενη υποενότητα.

3.4.4. Ανάλυση Συναισθήματος με LLM

Τα σύγχρονα LLMs μετατόπισαν το πεδίο της ανάλυσης συναισθήματος. Μοντέλα όπως οι παραλλαγές των LLaMA και GPT, και εξειδικευμένα χρηματοοικονομικά μοντέλα όπως το FinGPT [55], επιτυγχάνουν ανώτερη ακρίβεια χάρη στη βαθιά κατανόηση συμφραζομένων και την ικανότητα συλλογιστικής. Αντί απλής ταξινόμησης, ένα LLM μπορεί να παραγάγει μια βαθμολογημένη εκτίμηση συναισθήματος συνοδευόμενη ακόμη και από αιτιολόγηση.

Στην παρούσα εργασία, ένα LLM προσαρμόζεται στη χρηματοοικονομική/επενδυτική γλώσσα ώστε να εξάγει έναν *αριθμητικό δείκτη συναισθήματος* που να είναι σταθερός, αναπαραγώγιμος και συγχρονισμένος με τα χρονικά βήματα της αγοράς. Ο δείκτης αυτός αξιοποιείται διττά από τον πράκτορα DRL: αφενός ως πρόσθετο χαρακτηριστικό της κατάστασης, αφετέρου ως μηχανισμός προσαρμογής της έντασης των ενεργειών. Η ενσωμάτωση LLM-σημάτων συναισθήματος ως εξωγενών μεταβλητών σε συστήματα DRL αποτελεί ανοιχτό ερευνητικό ζήτημα, με κεντρικό πρόβλημα τον βέλτιστο τρόπο σύντηξης (data fusion) κειμενικής και αριθμητικής πληροφορίας.

3.4.5. Αποδοτική Μικρο-προσαρμογή: Low-Rank Adaptation (LoRA)

Η πλήρης μικρο-προσαρμογή (full fine-tuning) ενός LLM, που ενημερώνει το σύνολο των δισεκατομμυρίων παραμέτρων, είναι υπολογιστικά απαγορευτική για τους περισσότερους ερευνητές, λόγω των τεράστιων απαιτήσεων μνήμης GPU. Οι τεχνικές Αποδοτικής ως προς τις Παραμέτρους Μικρο-προσαρμογής (Parameter-Efficient Fine-Tuning, PEFT) αντιμετωπίζουν το πρόβλημα ενημερώνοντας μόνο ένα μικρό υποσύνολο παραμέτρων.

Η σημαντικότερη μέθοδος PEFT είναι η Προσαρμογή Χαμηλής Βαθμίδας (Low-Rank Adaptation, LoRA) [24]. Η βασική ιδέα στηρίζεται στην παρατήρηση ότι η μεταβολή των βαρών κατά τη μικρο-προσαρμογή έχει χαμηλή «εγγενή βαθμίδα» (intrinsic rank). Έτσι, αντί να ενημερώνεται ο πλήρης πίνακας βαρών $\mathbf{W}_0 \in \mathbb{R}^{d \times k}$, αυτός παγώνει και η μεταβολή $\Delta \mathbf{W}$ αναπαρίσταται ως γινόμενο δύο πολύ μικρότερων πινάκων:

$$\mathbf{W} = \mathbf{W}_0 + \Delta \mathbf{W} = \mathbf{W}_0 + \mathbf{B}\mathbf{A}, \quad (3.47)$$

όπου $\mathbf{B} \in \mathbb{R}^{d \times r}$, $\mathbf{A} \in \mathbb{R}^{r \times k}$ και η βαθμίδα $r \ll \min(d, k)$. Κατά την εκπαίδευση, εν προκειμένω σε δεδομένα χρηματοοικονομικού συναισθήματος, ενημερώνονται μόνο οι πίνακες $\mathbf{A}$ και $\mathbf{B}$, μειώνοντας τον αριθμό των εκπαιδευσιμων παραμέτρων κατά τάξεις μεγέθους και περιορίζοντας δραστικά τις απαιτήσεις μνήμης, χωρίς ουσιαστική απώλεια ακρίβειας. Επιπλέον, καθώς το $\mathbf{W}_0$ παραμένει αναλλοίωτο, για κάθε εξειδίκευση χρειάζεται να αποθηκευτούν μόνο οι δύο μικροί πίνακες $\mathbf{A}$ και $\mathbf{B}$, και όχι ένα πλήρες αντίγραφο του βασικού μοντέλου. Αυτό σημαίνει ότι διαφορετικά σύνολα LoRA παραμέτρων, εκπαιδευμένα για διαφορετικές εργασίες ή πεδία (π.χ. ανάλυση συναισθήματος κρυπτονομισμάτων έναντι παραδοσιακών μετοχών), μπορούν να εναλλάσσονται δυναμικά κατά τη διάρκεια της εξαγωγής συμπερασμάτων, απλώς αντικαθιστώντας τους πίνακες $\mathbf{A}$ και $\mathbf{B}$, χωρίς καμία μεταβολή στα παγωμένα βάρη $\mathbf{W}_0$. Αυτή η ιδιότητα καθιστά τη LoRA ιδιαίτερα ελκυστική για σενάρια πολλαπλών εξειδικεύσεων σε περιορισμένη υπολογιστική υποδομή, όπως είναι η παρούσα εφαρμογή.

3.5. Χρηματοοικονομικές Συναλλαγές

Η τελευταία ενότητα του θεωρητικού υποβάθρου εισάγει τις έννοιες των χρηματοοικονομικών αγορών που είναι απαραίτητες για τη διατύπωση του προβλήματος ως διαδικασίας λήψης αποφάσεων, καθώς και τα μέτρα αξιολόγησης της απόδοσης ενός πράκτορα συναλλαγών.

3.5.1. Βασικές Έννοιες στις Χρηματοοικονομικές Αγορές

Μια χρηματοοικονομική αγορά είναι ένας μηχανισμός όπου αγοραστές και πωλητές ανταλλάσσουν περιουσιακά στοιχεία (assets), μετοχές, ομόλογα, συνάλλαγμα, κρυπτονομίσματα.

Η τιμή ενός στοιχείου διαμορφώνεται από τη δυναμική προσφοράς και ζήτησης. Θεμελιώδεις έννοιες είναι:

- **Τιμές προσφοράς/ζήτησης** (bid/ask): η υψηλότερη τιμή που είναι διατεθειμένος να πληρώσει ένας αγοραστής (bid) και η χαμηλότερη που δέχεται ένας πωλητής (ask). Η διαφορά τους είναι το *περιθώριο* (spread).
- **Ρευστότητα** (liquidity): η ευκολία αγοραπωλησίας χωρίς σημαντική επίδραση στην τιμή.
- **Βιβλίο εντολών** (order book): η συγκεντρωτική καταγραφή των ενεργών εντολών αγοράς και πώλησης.
- **Μεταβλητότητα** (volatility): η έκταση των διακυμάνσεων της τιμής, τυπικά μετρούμενη ως η τυπική απόκλιση των αποδόσεων.

Η *χρηματοοικονομική απόδοση* (financial return) ενός στοιχείου μεταξύ δύο διαδοχικών χρονικών στιγμών ορίζεται είτε ως απλή ποσοστιαία μεταβολή είτε ως λογαριθμική απόδοση:

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}}, \quad r_t^{\log} = \ln\left(\frac{P_t}{P_{t-1}}\right). \quad (3.48)$$

Οι λογαριθμικές αποδόσεις προτιμώνται λόγω της ιδιότητας της χρονικής προσθετικότητας. Διευκρινίζεται ότι η έννοια αυτή είναι διαφορετική από την *απόδοση* της Ενισχυτικής Μάθησης (return στην ορολογία RL, ορισμός στην Ενότητα 3.3.1), η οποία εκφράζει τη *σωρευτική προεξοφλημένη ανταμοιβή* $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$ και αποτελεί λογιστική ποσότητα που χρησιμοποιείται για τη βελτιστοποίηση της πολιτικής, όχι μέτρο της μεταβολής τιμής. Στην παρούσα εργασία, η χρηματοοικονομική απόδοση r_t αποτελεί τη βάση του σήματος ανταμοιβής που λαμβάνει ο πράκτορας, ενώ ο στόχος βελτιστοποίησης είναι η RL απόδοση G_t .

Υπόθεση Αποτελεσματικής Αγοράς. Η *Υπόθεση Αποτελεσματικής Αγοράς* (Efficient Market Hypothesis, EMH) [16] υποστηρίζει ότι οι τιμές ενσωματώνουν άμεσα όλη τη διαθέσιμη πληροφορία, καθιστώντας θεωρητικά αδύνατη τη σταθερή υπεραπόδοση. Η *ημι-ισχυρή* μορφή της υποδεικνύει ότι οι τιμές προσαρμόζονται ταχύτατα στις νέες δημόσιες πληροφορίες, οι οποίες όμως συχνά εμφανίζονται πρώτα σε κειμενική μορφή, γεγονός που θεμελιώνει τη χρησιμότητα της ανάλυσης συναισθήματος. Παρά την επιρροή της EMH, η συμπεριφορική χρηματοοικονομική τεκμηριώνει συστηματικές αναποτελεσματικότητες οφειλόμενες σε ψυχολογικούς παράγοντες, ιδίως σε αγορές υψηλής κερδοσκοπίας και λιανικής συμμετοχής όπως τα κρυπτονομίσματα.

3.5.2. Χρηματοοικονομικά Δεδομένα, Κεριά και Θέσεις

Δεδομένα OHLCV και κεριά. Στην πράξη, τα δεδομένα τιμών συγκεντρώνονται σε διακριτά χρονικά διαστήματα (π.χ. λεπτό, ώρα, ημέρα) και αναπαρίστανται με τη μορφή *OHLCV*: τιμή ανοίγματος (Open), υψηλότερη (High), χαμηλότερη (Low), κλεισίματος (Close) και όγκος συναλλαγών (Volume). Κάθε τέτοια εγγραφή απεικονίζεται οπτικά ως ένα *κερί* (candlestick) (Σχήμα 3.4): το «σώμα» εκτείνεται μεταξύ ανοίγματος και κλεισίματος, ενώ οι «σκιές» φτάνουν στη μέγιστη και ελάχιστη τιμή. Ένα πράσινο (ανοδικό) κερί υποδηλώνει κλείσιμο υψηλότερο του ανοίγματος, ένα κόκκινο (πτωτικό) το αντίθετο.




Figure 3.4.: Δομή ενός ανοδικού (αριστερά) και ενός πτωτικού (δεξιά) κεριού. Το σώμα ορίζεται από το άνοιγμα και το κλείσιμο, ενώ οι σκιές δείχνουν το εύρος υψηλότερης-χαμηλότερης τιμής εντός του διαστήματος.

Θέσεις. Μια θέση (position) εκφράζει την έκθεση του συναλλασσόμενου σε ένα στοιχείο. Διακρίνονται:

- **Θέση αγοράς (long):** ο συναλλασσόμενος κατέχει το στοιχείο και επωφελείται από άνοδο της τιμής.
- **Θέση πώλησης (short):** ο συναλλασσόμενος έχει δανειστεί και πουλήσει το στοιχείο, επωφελούμενος από πτώση της τιμής.
- **Ουδέτερη θέση (flat):** καμία έκθεση στην αγορά.

Στον προτεινόμενο πράκτορα, ο χώρος δράσεων αντιστοιχεί ακριβώς στη ρύθμιση αυτής της θέσης (π.χ. άνοιγμα, κλείσιμο ή προσαρμογή του μεγέθους μιας θέσης), ενώ η κατάσταση του περιβάλλοντος περιλαμβάνει την τρέχουσα θέση μαζί με τα χαρακτηριστικά της αγοράς και το σήμα συναισθήματος.

3.5.3. Κέρδος και Ζημία (Profit and Loss)

Το *Κέρδος και Ζημία* (Profit and Loss, PnL) είναι το θεμελιώδες μέτρο της απόδοσης μιας συναλλακτικής δραστηριότητας. Διακρίνεται σε *μη πραγματοποιημένο* (unrealized), που αφορά ανοιχτές θέσεις αποτιμημένες στην τρέχουσα τιμή, και *πραγματοποιημένο* (realized),

που αποκρυσταλλώνεται με το κλείσιμο μιας θέσης. Για μια θέση μεγέθους q που ανοίγει στην τιμή P_{in} και κλείνει στην P_{out} , το ακαθάριστο PnL είναι:

$$\text{PnL} = q (P_{\text{out}} - P_{\text{in}}), \quad (3.49)$$

με $q > 0$ για θέση αγοράς και $q < 0$ για θέση πώλησης.

Κρισίμως, η πραγματική απόδοση πρέπει να αφαιρεί τα *κόστη συναλλαγών* (transaction costs)/προμήθειες, περιθώριο bid/ask και *ολίσθηση* (slippage), δηλαδή τη διαφορά μεταξύ αναμενόμενης και πραγματικής τιμής εκτέλεσης. Το καθαρό PnL για μια ακολουθία συναλλαγών γίνεται:

$$\text{PnL}_{\text{net}} = \sum_t q_t (P_{\text{out},t} - P_{\text{in},t}) - \sum_t c |\Delta q_t| P_t, \quad (3.50)$$

όπου c είναι ο αναλογικός συντελεστής κόστους ανά συναλλαγή. Η ενσωμάτωση αυτών των κοστών είναι απαραίτητη: μια στρατηγική κερδοφόρα σε θεωρητικό επίπεδο μπορεί να καταστεί ζημιογόνα μόλις ληφθούν υπόψη τα κόστη υψηλής συχνότητας συναλλαγών. Στον πράκτορα DRL, το καθαρό PnL αποτελεί τη βάση της συνάρτησης ανταμοιβής, η οποία μπορεί επιπλέον να ενσωματώνει όρους ποινής για τον κίνδυνο.

3.5.4. Ενεργό Κέρδος (Alpha) και Μέτρα Προσαρμοσμένα στον Κίνδυνο

Η αξιολόγηση μιας στρατηγικής με βάση μόνο το απόλυτο κέρδος είναι παραπλανητική, καθώς αγνοεί τόσο τον αναλαμβανόμενο κίνδυνο όσο και την απόδοση που θα προέκυπτε από μια παθητική επένδυση στην αγορά.

Ενεργό κέρδος (alpha). Το *ενεργό κέρδος* ή *άλφα* (alpha, α) μετρά την υπερβάλλουσα απόδοση μιας στρατηγικής πέραν εκείνης που δικαιολογείται από την έκθεσή της στον συστηματικό κίνδυνο της αγοράς. Με βάση το Υπόδειγμα Αποτίμησης Κεφαλαιουχικών Στοιχείων (CAPM), η αναμενόμενη απόδοση ενός χαρτοφυλακίου p διατυπώνεται ως:

$$\mathbb{E}[r_p] = r_f + \beta_p (\mathbb{E}[r_m] - r_f) + \alpha, \quad (3.51)$$

όπου r_f η απόδοση χωρίς κίνδυνο, r_m η απόδοση της αγοράς και β_p ο συντελεστής συστηματικού κινδύνου [26]. Θετικό α υποδηλώνει ότι η στρατηγική παράγει αξία πέρα από την απλή έκθεση στην αγορά, ακριβώς ο στόχος ενός ευφυούς πράκτορα συναλλαγών.

Μέτρα προσαρμοσμένα στον κίνδυνο. Για την ολοκληρωμένη αξιολόγηση χρησιμοποιούνται μέτρα που σταθμίζουν την απόδοση με τον κίνδυνο (Πίνακας 3.3). Ο Λόγος

Sharpe (*Sharpe Ratio*) [47] είναι ο πλέον διαδεδομένος:

$$\text{Sharpe} = \frac{\mathbb{E}[r_p] - r_f}{\sigma_p}, \quad (3.52)$$

όπου σ_p η τυπική απόκλιση των αποδόσεων. Ο *Λόγος Sortino* αντικαθιστά την σ_p με την απόκλιση μόνο των αρνητικών αποδόσεων (*downside deviation*), τιμωρώντας μόνο τον ανεπιθύμητο κίνδυνο. Η *Μέγιστη Πτώση Κεφαλαίου* (*Maximum Drawdown*) μετρά τη μεγαλύτερη σωρευτική απώλεια από μια κορυφή έως μια κοιλάδα και αποτυπώνει τον κίνδυνο καταστροφικών ζημιών.

Table 3.3.: Βασικά μέτρα αξιολόγησης απόδοσης στρατηγικών συναλλαγών.

Μέτρο	Τι μετρά	Επιθυμητή τιμή
Sharpe Ratio	απόδοση ανά μονάδα συνολικού κινδύνου	υψηλή
Sortino Ratio	απόδοση ανά μονάδα αρνητικού κινδύνου	υψηλή
Max Drawdown	μέγιστη σωρευτική απώλεια	χαμηλή (απ. τιμή)
α (alpha)	υπεραπόδοση έναντι αγοράς	θετική
Calmar Ratio	απόδοση ανά μονάδα μέγ. πτώσης	υψηλή

Στην παρούσα εργασία, τα μέτρα αυτά χρησιμεύουν τόσο για την αντικειμενική σύγκριση του προτεινόμενου πράκτορα με σημεία αναφοράς (*baselines*), όσο και, ενδεχομένως, ως συστατικά της συνάρτησης ανταμοιβής, ώστε ο πράκτορας να ενθαρρύνεται όχι απλώς να κερδίζει, αλλά να κερδίζει με ελεγχόμενο κίνδυνο.

3.5.5. Τεχνητή Νοημοσύνη στις Συναλλαγές

Η εφαρμογή DRL στις αγορές κρυπτονομισμάτων παρουσιάζει ορισμένες ιδιαιτέρως απαιτητικές προκλήσεις που δεν αντιμετωπίζονται επαρκώς στη βιβλιογραφία παραδοσιακών αγορών [38, 13]. Κεντρικό ζήτημα είναι η *μη στασιμότητα*: οι αγορές κρυπτονομισμάτων λειτουργούν 24/7 και υπόκεινται σε απότομες μεταβολές καθεστώτος (*regime shifts*), στις οποίες στατιστικές ιδιότητες των δεδομένων, όπως η μεταβλητότητα και οι συσχετίσεις μεταξύ στοιχείων, μεταβάλλονται ριζικά. Ένας πράκτορας εκπαιδευμένος σε μια περίοδο *bull market* ενδέχεται να αποτύχει κατάφωρα υπό συνθήκες *bear market* ή και αντιστρόφως, κάτι που επιβάλλει τη χρήση μεθόδων αξιολόγησης που ελέγχουν ρητά τη γενίκευση διαχρονικά.

Δεύτερη ιδιαιτερότητα είναι ο κίνδυνος *υπερπροσαρμογής στο παρελθόν* (*backtest overfitting*) [33]: ο υπερπαραμετρικός χώρος των DRL πρακτόρων είναι τόσο μεγάλος ώστε να υπάρχει σημαντικός κίνδυνος επιλογής υπερπαραμέτρων που αξιοποιούν ιδιοσυγκρασίες του ιστορικού δείγματος εκπαίδευσης χωρίς πραγματική γενικευσιμότητα. Συνδεδόμενο με αυτό είναι το πρόβλημα της *διαρροής μελλοντικής πληροφορίας* (*look-ahead bias*), στο οποίο χαρακτηριστικά ή σήματα που κατασκευάζονται στο παρόν χρησιμοποιούν άθελα μελλοντικά

δεδομένα κατά τη φάση του backtest. Ιδιαίτερη επιφυλακή απαιτείται για τα σήματα συναισθήματος που προέρχονται από LLM: εάν τα δεδομένα κειμένου δεν ευθυγραμμίζονται με ακρίβεια στο χρόνο με τις τιμές της αγοράς, εισάγεται συστηματικό look-ahead bias.

Στην παρούσα εργασία, και οι δύο κίνδυνοι αντιμετωπίζονται με τη χρήση Combinatorial Purged Cross-Validation (CPCV) [33], μιας μεθόδου που ειδικά σχεδιάστηκε για χρονοσειρές και επιβάλλει εμπάργκο μεταξύ ζωνών εκπαίδευσης και επαλήθευσης, εξαλείφοντας τις διαρροές πληροφορίας. Η βελτιστοποίηση υπερπαραμέτρων διεξάγεται ολοκληρωτικά εντός της CPCV διαδικασίας, ενώ η τελική αξιολόγηση πραγματοποιείται σε αυστηρά διαχωρισμένο χρονικό τμήμα (2024-2025) που δεν χρησιμοποιήθηκε σε κανένα στάδιο της εκπαίδευσης ή επιλογής μοντέλου. Η ακριβής μεθοδολογία αξιολόγησης παρουσιάζεται στο επόμενο κεφάλαιο.

4

Προτεινόμενη Μέθοδος

5

Πειράματα - Αποτελέσματα

6

Συμπεράσματα

References

- [1] Eitan Altman. *Constrained Markov Decision Processes*. Chapman and Hall/CRC, Boca Raton, FL, 1999. 24
- [2] Dogu Araci. Finbert: Financial sentiment analysis with pre-trained language models. *arXiv preprint arXiv:1908.10063*, 2019. 8, 29
- [3] Kai Arulkumaran, Marc Peter Deisenroth, Miles Brundage, and Anil Anthony Bharath. Deep reinforcement learning: A brief survey. *IEEE Signal Processing Magazine*, 34(6):26–38, 2017. 1
- [4] Stelios D. Bekiros. Fuzzy adaptive decision-making for boundedly rational traders in speculative stock markets. *European Journal of Operational Research*, 202(1):285–293, 2010. 1
- [5] Richard Bellman. *Dynamic Programming*. Princeton University Press, Princeton, NJ, 1957. 22
- [6] Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2):157–166, 1994. 19
- [7] Victor L. Bernard and Jacob K. Thomas. Post-earnings-announcement drift: Delayed price response or risk premium? *Journal of Accounting Research*, 27:1–36, 1989. 7
- [8] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, New York, 2006. 11
- [9] Johan Bollen, Huina Mao, and Xiaojun Zeng. Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1):1–8, 2011. 2, 8
- [10] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 1877–1901, 2020. 2, 28
- [11] Kyunghyun Cho, Bart van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using rnn encoder–decoder for statistical machine translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724–1734, 2014. 20
- [12] George Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989. 14

- [13] Yue Deng, Feng Bao, Youyong Kong, Zhiquan Ren, and Qionghai Dai. Deep direct reinforcement learning for financial signal representation and trading. *IEEE Transactions on Neural Networks and Learning Systems*, 28(3):653–664, 2017. 34
- [14] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, pages 4171–4186, 2019. 28
- [15] Stefan Elfving, Eiji Uchibe, and Kenji Doya. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning. *Neural Networks*, 107:3–11, 2018. 16
- [16] Eugene F. Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970. 7, 31
- [17] Thomas Fischer and Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018. 6
- [18] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, Cambridge, MA, 2016. 1, 13
- [19] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2nd edition, 2009. 11, 12
- [20] Matthew Hausknecht and Peter Stone. Deep recurrent q-learning for partially observable mdps. In *AAAI Fall Symposium Series*, 2015. 23
- [21] Dan Hendrycks and Kevin Gimpel. Gaussian error linear units (gelus). *arXiv preprint arXiv:1606.08415*, 2016. 16
- [22] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. 19
- [23] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989. 14
- [24] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. In *10th International Conference on Learning Representations (ICLR)*, 2022. 30
- [25] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 448–456, 2015. 19
- [26] Michael C. Jensen. The performance of mutual funds in the period 1945–1964. *The Journal of Finance*, 23(2):389–416, 1968. 33

- [27] Zhengyao Jiang and Jinjun Liang. Cryptocurrency portfolio management with deep reinforcement learning. In *2017 Intelligent Systems Conference (IntelliSys)*, pages 905–913. IEEE, 2017. 2
- [28] Leslie Pack Kaelbling, Michael L. Littman, and Anthony R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1–2):99–134, 1998. 22
- [29] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *3rd International Conference on Learning Representations (ICLR)*, 2015. 18
- [30] Jens Kober, J. Andrew Bagnell, and Jan Peters. Reinforcement learning in robotics: A survey. *The International Journal of Robotics Research*, 32(11):1238–1274, 2013. 5
- [31] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015. 1, 13
- [32] Xiao-Yang Liu, Zhuoran Xiong, Shan Zhong, Hongyang Yang, and Anwar Walid. Practical deep reinforcement learning approach for stock trading. *arXiv preprint arXiv:1811.07522*, 2018. 7
- [33] Marcos López de Prado. *Advances in Financial Machine Learning*. John Wiley & Sons, Hoboken, NJ, 2018. 34, 35
- [34] Tim Loughran and Bill McDonald. When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *The Journal of Finance*, 66(1):35–65, 2011. 8, 29
- [35] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, New York, 1997. 1, 11
- [36] Volodymyr Mnih, Adrià Puigdomènech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1928–1937, 2016. 25
- [37] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015. 5, 24
- [38] John Moody and Matthew Saffell. Learning to trade via direct reinforcement. *IEEE Transactions on Neural Networks*, 12(4):875–889, 2001. 2, 34
- [39] Vinod Nair and Geoffrey E. Hinton. Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th International Conference on Machine Learning (ICML)*, pages 807–814, 2010. 15
- [40] Jigar Patel, Sahil Shah, Priyank Thakkar, and K. Kotecha. Predicting stock and stock price index movement using trend deterministic data preparation and machine learning techniques. *Expert Systems with Applications*, 42(1):259–268, 2015. 6

- [41] Prajit Ramachandran, Barret Zoph, and Quoc V. Le. Searching for activation functions. *arXiv preprint arXiv:1710.05941*, 2017. 16
- [42] Frank Rosenblatt. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6):386–408, 1958. 14
- [43] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986. 18
- [44] John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 1889–1897, 2015. 26
- [45] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *4th International Conference on Learning Representations (ICLR)*, 2016. 25
- [46] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. 5, 26
- [47] William F. Sharpe. Mutual fund performance. *The Journal of Business*, 39(1):119–138, 1966. 34
- [48] David Silver, Aja Huang, Chris J. Maddison, Arthur Guez, Laurent Sifre, George van den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016. 5
- [49] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958, 2014. 19
- [50] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, 2nd edition, 2018. 1, 13, 21
- [51] John L. Teall. *Financial Trading and Investing*. Academic Press, 2022.
- [52] Paul C. Tetlock. Giving content to investor sentiment: The role of media in the stock market. *The Journal of Finance*, 62(3):1139–1168, 2007. 8
- [53] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017. 27
- [54] Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3–4):229–256, 1992. 25

-
- [55] Hongyang Yang, Xiao-Yang Liu, and Christina Dan Wang. Fingpt: Open-source financial large language models. *arXiv preprint arXiv:2306.06031*, 2023. 8, 29
 - [56] Hongyang Yang, Xiao-Yang Liu, Shan Zhong, and Anwar Walid. Deep reinforcement learning for automated stock trading: An ensemble strategy. In *Proceedings of the First ACM International Conference on AI in Finance (ICAIF)*, pages 1–8, 2020. 7
 - [57] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deeplob: Deep convolutional neural networks for limit order books. *IEEE Transactions on Signal Processing*, 67(11):3001–3012, 2019. 6



Appendix
