



ARISTOTLE UNIVERSITY OF THESSALONIKI

ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ

Πολυτεχνική Σχολή

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Τομέας Ηλεκτρονικής και Υπολογιστών

Τεχνικές βαθιάς μάθησης για υλοποίηση προσαρμοστικών πρακτόρων με εφαρμογή στις χρηματοοικονομικές συναλλαγές

Χαράλαμπος Κεμαλίδης

Faculty of Sciences

School of Informatics

Month 2025

*This thesis is submitted in partial fulfilment of the requirements
for the Degree of Informatics*

Copyright © 2025 Χαράλαμπος Κεμαλίδης

Typeset by the author with the Xe_{La}TeX documentation system.

Month 2025.



ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ
Σχολή Θετικών Επιστημών
Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης

Τεχνικές βαθιάς μάθησης για υλοποίηση
προσαρμοστικών πρακτόρων με εφαρμογή
στην ρομποτική και στις
χρηματοοικονομικές συναλλαγές

Όνομα Συγγραφέα

Επιβλέπων Καθηγητής:

Σχολή Θετικών Επιστημών
Τμήμα Πληροφορικής

Μήνας Έτος

Περίληψη

Abstract

Ευχαριστίες

Contents

Περίληψη	ii
Abstract	iii
Ευχαριστίες	iv
Contents	v
List of Figures	vii
List of Tables	viii
1. Εισαγωγή	1
1.1. Πλαίσιο & Κίνητρο	1
1.2. Διατύπωση προβλήματος	2
1.3. Στόχος και προτεινόμενη προσέγγιση	3
1.4. Αξιολόγηση	4
1.5. Συνεισφορές	4
1.6. Δομή Εργασίας	4
2. Επισκόπηση της Ερευνητικής Περιοχής	6
2.1. Από τα Κλειστά Προσομοιωμένα Περιβάλλοντα στα Ανοιχτά Στοχαστικά Συστήματα	6
2.2. Τεχνητή Νοημοσύνη και Μηχανική Μάθηση στις Αγορές	7
2.3. Βαθιά Μάθηση στις Χρηματοοικονομικές Συναλλαγές	7
2.4. Ενισχυτική Μάθηση και Ακολουθιακή Λήψη Αποφάσεων	8
2.5. Ανάλυση Συναισθήματος και Εναλλακτικά Δεδομένα	8
2.5.1. Οικονομικές Ειδήσεις και Μέσα Κοινωνικής Δικτύωσης	8
2.5.2. Από τα Λεξικά στα Μεγάλα Γλωσσικά Μοντέλα (LLMs)	9
3. Θεωρητικό Υπόβαθρο	10
3.1. Μηχανική Μάθηση	10
3.2. Νευρωνικά Δίκτυα και Βαθιά Μάθηση	11
3.2.1. Συναρτήσεις Ενεργοποίησης	11
3.2.2. Βελτιστοποίηση και Αλγόριθμος Adam	12

3.2.3. Δίκτυα Μακράς Βραχύχρονης Μνήμης (LSTM)	12
3.3. Βαθιά Ενισχυτική Μάθηση	13
3.3.1. Μέθοδοι Δρώντος-Κριτή (Actor-Critic)	13
3.3.2. Βελτιστοποίηση Εγγύς Πολιτικής (Proximal Policy Optimization - PPO)	14
3.4. Επεξεργασία Φυσικής Γλώσσας και Μεγάλα Γλωσσικά Μοντέλα (LLMs) . .	15
3.4.1. Αποδοτική Μικρο-προσαρμογή: Low-Rank Adaptation (LoRA) . . .	15
3.5. Χρηματοοικονομικές Συναλλαγές και Αξιολόγηση Μοντέλων	15
3.5.1. Χρηματοοικονομικά Δεδομένα και Ανάλυση	16
3.5.2. Αξιολόγηση σε Χρονοσειρές: Combinatorial Purged Cross-Validation (CPCV)	16
4. Experimental Evaluation	17
5. Conclusions & Future Work	18
References	19
A'.Appendix	20

List of Figures

List of Tables

1.1. Πλαίσιο & Κίνητρο

Η Τεχνητή Νοημοσύνη (Artificial Intelligence) αποτελεί ένα ταχέως εξελισσόμενο επιστημονικό και τεχνολογικό πεδίο με εφαρμογή σε πολλούς κλάδους της ανθρώπινης δραστηριότητας. Ασχολείται με τη σχεδίαση και υλοποίηση υπολογιστικών συστημάτων ικανών να αναπαράγουν γνωστικές λειτουργίες ενός ανθρώπου όπως είναι η μάθηση, ο σχεδιασμός, η δημιουργικότητα, η προσαρμοστικότητα, η εξαγωγή συμπερασμάτων, η κατανόηση από συμφραζόμενα, η επίλυση προβλημάτων και άλλες.

Η Μηχανική Μάθηση (Machine Learning) αποτελεί έναν από τους σημαντικότερους κλάδους της Τεχνητής Νοημοσύνης, καθώς παρέχει τη δυνατότητα ανάπτυξης συστημάτων που βελτιώνουν την απόδοσή τους μέσω της εμπειρίας και της ανάλυσης δεδομένων [?]. Ανάμεσα στις επιμέρους προσεγγίσεις της, η Βαθιά Μάθηση (Deep Learning) έχει αναδειχθεί ως ιδιαίτερα αποτελεσματική στην αντιμετώπιση σύνθετων προβλημάτων υψηλής διάστασης, αξιοποιώντας πολυεπίπεδα νευρωνικά δίκτυα για την αυτόματη εξαγωγή αναπαραστάσεων και προτύπων από τα δεδομένα [?]. Παράλληλα, η Ενισχυτική Μάθηση (Reinforcement Learning) επικεντρώνεται στη μάθηση μέσω αλληλεπίδρασης με το περιβάλλον, επιτρέποντας σε έναν πράκτορα να προσαρμόζει τη συμπεριφορά του με βάση τις ανταμοιβές που λαμβάνει [?]. Ο συνδυασμός των δύο αυτών περιοχών οδήγησε στη Βαθιά Ενισχυτική Μάθηση (Deep Reinforcement Learning – DRL), η οποία έχει επιτύχει αξιοσημείωτα αποτελέσματα σε προβλήματα ακολουθιακής λήψης αποφάσεων, όπως η ρομποτική, τα αυτόνομα συστήματα, η υγειονομική περίθαλψη και οι χρηματοοικονομικές συναλλαγές [?].

Η ανάπτυξη τεχνικών βαθιάς μάθησης έχει επιταχύνει σημαντικά την πρόοδο σε προβλήματα αντίληψης, πρόβλεψης και λήψης αποφάσεων υπό αβεβαιότητα [?]. Οι χρηματοοικονομικές συναλλαγές αποτελούν ένα ιδιαίτερα απαιτητικό πεδίο εφαρμογής της [?]. Σε αντίθεση με κλασικά προβλήματα πρόβλεψης, ο στόχος δεν είναι μόνο η εκτίμηση της μελλοντικής πορείας μιας τιμής, αλλά η λήψη κατάλληλων αποφάσεων αγοράς, πώλησης ή διακράτησης υπό συνθήκες αβεβαιότητας. Παρόλα αυτά, οι αγορές χαρακτηρίζονται από υψηλό θόρυβο, μεταβαλλόμενα καθεστώτα λειτουργίας, ισχυρή χρονική εξάρτηση και σημαντικά κόστη συ-

ναλλαγών, παράγοντες που καθιστούν δύσκολη τη γενίκευση των μοντέλων σε νέα δεδομένα.

Τα τελευταία χρόνια, σημαντικό μέρος της έρευνας έχει επικεντρωθεί στην αξιοποίηση νευρωνικών δικτύων και αλγορίθμων ενισχυτικής μάθησης για την ανάπτυξη αυτόνομων πρακτόρων συναλλαγών [?]. Σε αντίθεση με τις κλασικές προσεγγίσεις πρόβλεψης τιμών, η DRL βελτιστοποιεί άμεσα τη διαδοχική λήψη αποφάσεων μέσω συνάρτησης ανταμοιβής που μπορεί να ενσωματώνει κέρδος, κίνδυνο και κόστη συναλλαγών. Κάτι που είναι ιδιαίτερα χρήσιμο σε περιβάλλοντα υψηλού θορύβου και μη στασιμότητας τα οποία χαρακτηρίζονται μερικώς παρατηρήσιμα (Partially Observable Markov Decision Process – POMDP) όπως οι χρηματοοικονομικές αγορές (stocks, crypto), με το πραγματικό καθεστώς της αγοράς να μην είναι άμεσα ορατό.

Ωστόσο, οι περισσότερες προσεγγίσεις DRL βασίζονται κυρίως σε αριθμητικά δεδομένα αγοράς, όπως ιστορικές τιμές και τεχνικούς δείκτες, παραβλέποντας πληροφορία που προέρχεται από άλλες πηγές [?]. Παράλληλα, η αυξανόμενη διαθεσιμότητα ειδήσεων, οικονομικών αναφορών, αναρτήσεων και σχολιασμών στα μέσα κοινωνικής δικτύωσης έχει αναδείξει τη σημασία της ανάλυσης συναισθήματος (sentiment analysis) ως πιθανής πηγής πληροφορίας για την ερμηνεία της συμπεριφοράς των αγορών [?].

Η πρόσφατη ανάπτυξη των Μεγάλων Γλωσσικών Μοντέλων (Large Language Models – LLMs) έχει βελτιώσει σημαντικά την ικανότητα εξαγωγής σημασιολογικής πληροφορίας από κείμενο [?]. Παρότι τα μοντέλα αυτά έχουν εφαρμοστεί με επιτυχία σε προβλήματα επεξεργασίας φυσικής γλώσσας, η αποτελεσματική ενσωμάτωση των πληροφοριών που παράγουν σε συστήματα λήψης αποφάσεων για χρηματοοικονομικές συναλλαγές παραμένει ενεργό ερευνητικό ζήτημα.

1.2. Διατύπωση προβλήματος

Το πρόβλημα των χρηματοοικονομικών συναλλαγών μπορεί να διατυπωθεί ως πρόβλημα ακολουθιακής λήψης αποφάσεων, όπου ένας πράκτορας παρατηρεί την κατάσταση της αγοράς και επιλέγει ενέργειες με σκοπό τη μεγιστοποίηση μιας συνάρτησης ανταμοιβής που σχετίζεται με την απόδοση του χαρτοφυλακίου του. Η διατύπωση αυτή συνοδεύεται από σημαντικές δυσκολίες λόγω της μη στασιμότητας των αγορών, του θορύβου των δεδομένων και της περιορισμένης παρατηρησιμότητας του πραγματικού υποκείμενου καθεστώτος της αγοράς.

Επιπλέον, η διαθέσιμη πληροφορία δεν περιορίζεται στα αριθμητικά δεδομένα που προκύπτουν από τις τιμές των περιουσιακών στοιχείων. Η δημοσίευση ειδήσεων, οικονομικών γεγονότων ή η μεταβολή του επενδυτικού κλίματος μπορεί να επηρεάσει σημαντικά τη συμπεριφορά της αγοράς, ιδίως σε περιουσιακά στοιχεία υψηλής μεταβλητότητας όπως τα κρυπτονομίσματα. Παρότι μέρος αυτής της πληροφορίας αποτυπώνεται τελικά στις τιμές, δεν είναι σαφές κατά πόσο η αξιοποίησή της σε πρώιμο στάδιο μπορεί να βελτιώσει τη διαδικασία

λήψης αποφάσεων ενός πράκτορα συναλλαγών.

Η παρούσα εργασία εξετάζει κατά πόσο ένα σήμα συναισθήματος που παράγεται από ένα προσαρμοσμένο Μεγάλο Γλωσσικό Μοντέλο (LLM) μπορεί να λειτουργήσει συμπληρωματικά προς τα κλασικά χαρακτηριστικά αγοράς και να βελτιώσει την απόδοση ενός πράκτορα Βαθιάς Ενισχυτικής Μάθησης (DRL).

1.3. Στόχος και προτεινόμενη προσέγγιση

Στόχος της παρούσας εργασίας είναι η ανάπτυξη και αξιολόγηση ενός προσαρμοστικού πράκτορα χρηματοοικονομικών συναλλαγών που συνδυάζει πληροφορία αγοράς με πληροφορία προερχόμενη από χρηματοοικονομικά κείμενα. Η βασική ιδέα είναι ότι το κειμενικό σήμα μπορεί να προσφέρει συμπληρωματική πληροφορία σε σχέση με τα κλασικά αριθμητικά χαρακτηριστικά αγοράς, ιδιαίτερα σε περιόδους όπου η μεταβλητότητα, η αβεβαιότητα ή η κατεύθυνση της τάσης καθορίζονται σε σημαντικό βαθμό από την πληροφόρηση και τη συλλογική ψυχολογία.

Για τον σκοπό αυτό, ο προτεινόμενος προσαρμοστικός πράκτορας αποτελείται από δύο διακριτούς αλλά συμπληρωματικούς κορμούς:

1. **Ο πρώτος κορμός** αφορά την παραγωγή sentiment με τη χρήση ενός Μεγάλου Γλωσσικού Μοντέλου (Large Language Model - LLM), το οποίο έχει προσαρμοστεί στο πεδίο της χρηματοοικονομικής/επενδυτικής γλώσσας με χρήση τεχνικών αποδοτικής εκπαίδευσης παραμέτρων, συγκεκριμένα με Low Rank Adaptation (LoRA), αξιοποιώντας σχετικά δεδομένα από άρθρα και αναρτήσεις σε κοινωνικά δίκτυα. Στόχος είναι η εξαγωγή ενός αριθμητικού δείκτη sentiment που να είναι σταθερός, αναπαραγώγιμος και κατάλληλος για συγχρονισμό με χρονικά βήματα αγοράς.
2. **Ο δεύτερος κορμός** αφορά έναν πράκτορα ενισχυτικής μάθησης (DRL) με βαθύ αναδρομικό νευρωνικό δίκτυο (LSTM), ο οποίος εκπαιδεύεται με Proximal Policy Optimization (PPO). Η LSTM αρχιτεκτονική επιτρέπει την αξιοποίηση χρονικών εξαρτήσεων και τη διατήρηση μνήμης, κάτι που είναι κρίσιμο σε POMDP πλαίσιο όπου το ιστορικό φέρει πληροφορία για το καθεστώς της αγοράς.

Το sentiment αξιοποιείται διττά:

- (α) ως πρόσθετο χαρακτηριστικό εισόδου (feature) του μοντέλου DRL, ώστε να εμπλουτίζει την κατάσταση (state) του περιβάλλοντος (env) με κειμενικά-σημασιολογική πληροφορία, και
- (β) ως σήμα ενίσχυσης/μείωσης (amplify/reduce) της έντασης των ενεργειών (actions) του πράκτορα υπό συγκεκριμένες συνθήκες.

Με αυτόν τον τρόπο, το sentiment δεν αντιμετωπίζεται απλώς ως παθητικό χαρακτηριστικό, αλλά ως παράγοντας που μπορεί να επηρεάζει λειτουργικά την εκτελεστική συμπεριφορά του πράκτορα, επιτρέποντας στη στρατηγική να γίνεται πιο επιθετική ή πιο αμυντική ανάλογα με το πληροφοριακό περιεχόμενο του κειμενικού σήματος.

1.4. Αξιολόγηση

Η αξιολόγηση συστημάτων συναλλαγών σε χρονοσειρές απαιτεί ιδιαίτερη προσοχή, καθώς οι συμβατικές μέθοδοι τυχαίου διαχωρισμού δεδομένων μπορούν να οδηγήσουν σε διαρροή πληροφορίας και υπεραισιόδοξες εκτιμήσεις απόδοσης. Για τον λόγο αυτό χρησιμοποιείται η μέθοδος Combinatorial Purged Cross-Validation (CPCV), η οποία έχει σχεδιαστεί ειδικά για χρηματοοικονομικά δεδομένα με χρονική εξάρτηση. Η CPCV αξιοποιείται για την επιλογή των υπερπαραμέτρων του πράκτορα PPO-LSTM και των παραμέτρων που σχετίζονται με την ενσωμάτωση του sentiment, με στόχο τη βελτίωση της ικανότητας γενίκευσης και τη μείωση του κινδύνου υπερπροσαρμογής.

1.5. Συνεισφορές

Οι κύριες συνεισφορές της παρούσας εργασίας συνοψίζονται στα ακόλουθα:

- Προτείνεται μία υβριδική αρχιτεκτονική που συνδυάζει LLM-based sentiment analysis και Deep Reinforcement Learning για χρηματοοικονομικές συναλλαγές.
- Υλοποιείται προσαρμογή ενός Μεγάλου Γλωσσικού Μοντέλου με χρήση LoRA για την εξαγωγή sentiment από χρηματοοικονομικά κείμενα.
- Διερευνάται η διττή αξιοποίηση του sentiment ως χαρακτηριστικού κατάστασης και ως μηχανισμού προσαρμογής των ενεργειών ενός PPO-LSTM πράκτορα.
- Εφαρμόζεται διαδικασία επιλογής υπερπαραμέτρων βασισμένη σε Combinatorial Purged Cross-Validation, κατάλληλη για χρονικά εξαρτώμενα χρηματοοικονομικά δεδομένα.
- Παρουσιάζεται εκτενής πειραματική αξιολόγηση σε περιβάλλον συναλλαγών κρυπτονομισμάτων.

1.6. Δομή Εργασίας

Η εργασία οργανώνεται ως εξής. Στο Κεφάλαιο 2 παρουσιάζεται η σχετική βιβλιογραφία και η επισκόπηση της ερευνητικής περιοχής. Στο Κεφάλαιο 3 αναλύεται το απαραίτητο

θεωρητικό υπόβαθρο. Στο Κεφάλαιο 4 περιγράφεται η προτεινόμενη μεθοδολογία και η αρχιτεκτονική του συστήματος. Στο Κεφάλαιο 5 παρουσιάζονται τα πειραματικά αποτελέσματα και η αξιολόγηση της προτεινόμενης προσέγγισης. Τέλος, στο Κεφάλαιο 6 συνοψίζονται τα συμπεράσματα της εργασίας και διατυπώνονται προτάσεις για μελλοντική έρευνα.

Επισκόπηση της Ερευνητικής Περιοχής

2.1. Από τα Κλειστά Προσομοιωμένα Περιβάλλοντα στα Ανοιχτά Στοχαστικά Συστήματα

Η εντυπωσιακή πρόοδος της Βαθιάς Ενισχυτικής Μάθησης (DRL) συνδέεται ιστορικά με την επίτευξη επιδόσεων ανώτερων του ανθρώπινου επιπέδου (superhuman performance) σε κλειστά, προσομοιωμένα περιβάλλοντα παιχνιδιών. Ορόσημα όπως η επιτυχία του αλγορίθμου Deep Q-Network (DQN) στο περιβάλλον Atari [?] και η επικράτηση του AlphaGo στο απαιτητικό παιχνίδι του Go [?] απέδειξαν την ικανότητα των πρακτόρων DRL να επιλύουν σύνθετα προβλήματα ακολουθιακής λήψης αποφάσεων υψηλής διάστασης.

Ωστόσο, τα περιβάλλοντα αυτά χαρακτηρίζονται από πλήρη παρατηρησιμότητα (Fully Observable MDPs), σταθερούς ντετερμινιστικούς κανόνες και τη δυνατότητα δημιουργίας απεριόριστων δεδομένων μέσω εξομίωσης (Synthetic Data). Η προσπάθεια μεταφοράς αυτών των μοντέλων σε πραγματικά, ανοιχτά συστήματα —όπως η ρομποτική και η αυτόνομη οδήγηση— ανέδειξε σημαντικές προκλήσεις που σχετίζονται με τον θόρυβο των αισθητήρων, την περιορισμένη παρατηρησιμότητα και τη μη στασιμότητα (non-stationarity) του περιβάλλοντος [?].

Για την αντιμετώπιση αυτών των περιορισμών, η έρευνα στράφηκε προς δύο κατευθύνσεις: (α) την ενσωμάτωση αναδρομικών επιπέδων (DRQN / LSTM) για τη διατήρηση ιστορικής μνήμης σε Μερικώς Παρατηρήσιμα περιβάλλοντα (POMDP), και (β) την ανάπτυξη αλγορίθμων Policy Gradient με περιορισμούς στο μέγεθος του βήματος ενημέρωσης (Trust Region), όπως ο Proximal Policy Optimization (PPO) [?], οι οποίοι προσφέρουν σταθερότητα κάτω από συνθήκες έντονου θορύβου.

Η συγκεκριμένη μεθοδολογική εξέλιξη κρίνεται ως απολύτως αναγκαία για τη μεταφορά του DRL στο χρηματοοικονομικό πεδίο, το οποίο αποτελεί ίσως το πιο ακραίο παράδειγμα

ανοιχτού, στοχαστικού και μη στασίμου περιβάλλοντος.

2.2. Τεχνητή Νοημοσύνη και Μηχανική Μάθηση στις Αγορές

Η εφαρμογή αλγορίθμων Μηχανικής Μάθησης (Machine Learning - ML) για την ανάλυση και πρόβλεψη χρηματοοικονομικών χρονοσειρών αποτελεί αντικείμενο εκτενούς έρευνας εδώ και δεκαετίες. Οι παραδοσιακές στατιστικές μέθοδοι ανάλυσης χρονοσειρών, όπως η AutoRegressive Integrated Moving Average (ARIMA) και οι παραλλαγές της: Generalized Auto-Regressive Conditional Heteroscedasticity (GARCH) και ARMA, αλλά και τα Μοντέλα Παλινδρόμησης (Regression Models), αντικαταστάθηκαν σταδιακά από επιβλεπόμενες (supervised) τεχνικές μηχανικής μάθησης, όπως οι Μηχανές Διανυσμάτων Υποστήριξης (Support Vector Machines - SVM) και τα Τυχαία Δάση (Random Forests) [?].

Οι προσεγγίσεις αυτές επικεντρώθηκαν κυρίως στην κατηγοριοποίηση της κατεύθυνσης της τιμής (άνοδος/πτώση) ή στην παλινδρόμηση για την εκτίμηση της μελλοντικής απόδοσης. Παρά την αρχική τους επιτυχία, τα κλασικά μοντέλα ML παρουσιάζουν σημαντικούς περιορισμούς όταν καλούνται να διαχειριστούν τη μη γραμμικότητα, τον υψηλό θόρυβο και τη μη στασιμότητα (non-stationarity) που χαρακτηρίζουν τις σύγχρονες διεθνείς αγορές.

2.3. Βαθιά Μάθηση στις Χρηματοοικονομικές Συναλλαγές

Η έλευση της Βαθιάς Μάθησης (Deep Learning) επέτρεψε την αυτόματη εξαγωγή σύνθετων, μη γραμμικών αναπαραστάσεων από ακατέργαστα δεδομένα αγοράς (raw market data), εξαλείφοντας την ανάγκη για χειροκίνητο σχεδιασμό χαρακτηριστικών (manual feature engineering).

Τα Αναδρομικά Νευρωνικά Δίκτυα (Recurrent Neural Networks - RNNs) και ειδικότερα η αρχιτεκτονική Long Short-Term Memory (LSTM) καθιερώθηκαν ως η κυρίαρχη επιλογή για τη μοντελοποίηση χρηματοοικονομικών δεδομένων, λόγω της ικανότητάς τους να διατηρούν πληροφορίες για μεγάλα χρονικά διαστήματα και να διαχειρίζονται χρονικές εξαρτήσεις [?]. Παράλληλα, τα Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNNs) έχουν χρησιμοποιηθεί με επιτυχία για την αναγνώριση οπτικών προτύπων σε διαγράμματα τιμών (chart patterns) ή για τη γεωμετρική αναπαράσταση των βιβλίων εντολών (limit order books) [?].

Ωστόσο, η βιβλιογραφία αναδεικνύει ότι η απλή πρόβλεψη της τιμής (price forecasting) δεν μεταφράζεται απαραίτητα σε κερδοφόρα στρατηγική συναλλαγών, καθώς δεν λαμβάνει υπόψη τους περιορισμούς εκτέλεσης, τα κόστη συναλλαγών και τη δυναμική διαχείριση του

κινδύνου.

2.4. Ενισχυτική Μάθηση και Ακολουθιακή Λήψη Αποφάσεων

Για την γεφύρωση του χάσματος μεταξύ πρόβλεψης και εκτέλεσης, η έρευνα στράφηκε προς την Ενισχυτική Μάθηση (Reinforcement Learning - RL). Σε αντίθεση με την επιβλεπόμενη μάθηση, οι πράκτορες RL δεν εκπαιδεύονται να ελαχιστοποιούν ένα σφάλμα πρόβλεψης, αλλά να μεγιστοποιούν μια μακροπρόθεσμη συνάρτηση χρησιμότητας (όπως η σωρευτική απόδοση ή ο δείκτης Sharpe) μέσω της αλληλεπίδρασης με την αγορά.

Οι πρώτες απόπειρες βασίστηκαν σε tabular μεθόδους (Q-learning), αλλά ο συνδυασμός με τη βαθιά μάθηση (Deep Reinforcement Learning - DRL) επέτρεψε τη διαχείριση συνεχών και υψηλής διάστασης καταστάσεων (state spaces) [?]. Αλγόριθμοι που βασίζονται στην πολιτική (Policy Gradient methods), όπως ο Proximal Policy Optimization (PPO), έχουν επιδείξει εξαιρετική σταθερότητα σε περιβάλλοντα συναλλαγών [?].

Η ενσωμάτωση αναδρομικών επιπέδων (PPO-LSTM) επέτρεψε τη μοντελοποίηση της αγοράς ως Μερικώς Παρατηρήσιμη Μαρκοβιανή Διαδικασία Λήψης Αποφάσεων (POMDP), αναγνωρίζοντας ότι οι ιστορικές τιμές κρύβουν πληροφορίες για το μη εμφανές καθεστώς της αγοράς (market regime).

2.5. Ανάλυση Συναισθήματος και Εναλλακτικά Δεδομένα

Παρά την εξέλιξη των DRL πρακτόρων, η αποκλειστική χρήση ποσοτικών/αριθμητικών δεδομένων (ενδογενή δεδομένα αγοράς) θεωρείται από πολλούς ερευνητές ανεπαρκής, καθώς αντανακλά γεγονότα που έχουν ήδη συμβεί. Η θεωρία της Ημι-Ισχυρής Αποτελεσματικής Αγοράς υποδεικνύει ότι οι τιμές προσαρμόζονται άμεσα με την έλευση νέων πληροφοριών, οι οποίες συχνά εμφανίζονται πρώτα σε κειμενική μορφή.

2.5.1. Οικονομικές Ειδήσεις και Μέσα Κοινωνικής Δικτύωσης

Η ανάλυση συναισθήματος (Sentiment Analysis) σε χρηματοοικονομικά κείμενα χωρίζεται ιστορικά σε δύο κύριες πηγές:

1. **Επίσημες Χρηματοοικονομικές Ειδήσεις:** Πηγές όπως το Bloomberg, το Reuters ή εταιρικές ανακοινώσεις παρέχουν θεσμική, υψηλής εγκυρότητας πληροφορία που επηρεάζει κυρίως τις παραδοσιακές αγορές (μετοχές, ομόλογα) [?].

2. **Μέσα Κοινωνικής Δικτύωσης (Social Media):** Πλατφόρμες όπως το Twitter/X και το Reddit παράγουν δεδομένα υψηλής συχνότητας. Η βιβλιογραφία δείχνει ότι το περιεχόμενο αυτό είναι ιδιαίτερα κρίσιμο για περιουσιακά στοιχεία με υψηλό βαθμό κερδοσκοπίας και λιανικής συμμετοχής, όπως τα κρυπτονομίσματα, όπου η συλλογική ψυχολογία καθορίζει συχνά βραχυπρόθεσμες τάσεις [?].

2.5.2. Από τα Λεξικά στα Μεγάλα Γλωσσικά Μοντέλα (LLMs)

Οι πρώτες μέθοδοι εξαγωγής συναισθήματος βασίστηκαν σε στατικά λεξικά προσαρμοσμένα στα χρηματοοικονομικά, όπως το λεξικό Loughran-McDonald [?]. Αν και αποτελεσματικές για την εποχή τους, οι μέθοδοι αυτές αδυνατούσαν να συλλάβουν το συντακτικό πλαίσιο, τον σαρκασμό ή τις πολύπλοκες σημασιολογικές δομές.

Η εισαγωγή αρχιτεκτονικών Transformer (π.χ., FinBERT) βελτίωσε δραστικά την κατάσταση, προσφέροντας contextual αναπαραστάσεις [?]. Πρόσφατα, η έρευνα έχει μετατοπιστεί στα Μεγάλα Γλωσσικά Μοντέλα (LLMs), όπως οι παραλλαγές των LLaMA, GPT και εξειδικευμένων μοντέλων όπως το FinGPT [?]. Τα μοντέλα αυτά, όταν προσαρμόζονται με αποδοτικές μεθόδους (Parameter-Efficient Fine-Tuning - PEFT), όπως το Low-Rank Adaptation (LoRA), επιδεικνύουν ανώτερη ικανότητα zero-shot και few-shot συλλογιστικής, επιτρέποντας την ποσοτικοποίηση του επενδυτικού κλίματος με πρωτοφανή ακρίβεια.

Η ενοποίηση αυτών των LLM-based σημάτων συναισθήματος ως εξωγενών μεταβλητών σε DRL συστήματα λήψης αποφάσεων αποτελεί την τρέχουσα αιχμή του δόρατος στην αλγοριθμική έρευνα, με ανοιχτά ζητήματα που αφορούν τον βέλτιστο τρόπο σύντηξης (data fusion) των δύο αυτών διαφορετικών κόσμων (χειμενικού και αριθμητικού).

Θεωρητικό Υπόβαθρο

Το παρόν κεφάλαιο παραθέτει την αναλυτική θεωρητική θεμελίωση των εννοιών, των αρχιτεκτονικών και των αλγορίθμων που αποτελούν τον πυρήνα της προτεινόμενης μεθοδολογίας. Αρχικά, παρουσιάζονται οι βασικές αρχές της Μηχανικής Μάθησης και των Νευρωνικών Δικτύων, με ιδιαίτερη έμφαση στα Δίκτυα Μακράς Βραχύχρονης Μνήμης (LSTM) και τις τεχνικές βελτιστοποίησης. Στη συνέχεια, αναλύεται σε βάθος το μαθηματικό πλαίσιο της Βαθιάς Ενισχυτικής Μάθησης (DRL) και ο αλγόριθμος Proximal Policy Optimization (PPO). Ακολούθως, εισάγεται η θεωρία των Μεγάλων Γλωσσικών Μοντέλων (LLMs) και της αποδοτικής μικρο-προσαρμογής (LoRA). Το κεφάλαιο ολοκληρώνεται με την εξέταση των χρηματοοικονομικών αγορών, της υπόθεσης αποτελεσματικής αγοράς και των μεθόδων αξιολόγησης χρονοσειρών, όπως το Combinatorial Purged Cross-Validation (CPCV).

3.1. Μηχανική Μάθηση

Η μηχανική μάθηση (Machine Learning) αποτελεί κλάδο της τεχνητής νοημοσύνης, ο οποίος εστιάζει στην ανάπτυξη υπολογιστικών μοντέλων που έχουν την ικανότητα να μαθαίνουν από δεδομένα και να βελτιώνουν την απόδοσή τους χωρίς να απαιτείται ρητός προγραμματισμός[cite: 2]. Διακρίνεται σε τρεις κύριες κατηγορίες:

- **Επιβλεπόμενη Μάθηση (Supervised Learning):** Το μοντέλο εκπαιδεύεται χρησιμοποιώντας δεδομένα που περιέχουν ήδη γνωστές ετικέτες (labels), με στόχο να μάθει τη συνάρτηση που αντιστοιχεί τις εισόδους στις επιθυμητές εξόδους[cite: 2].
- **Μη Επιβλεπόμενη Μάθηση (Unsupervised Learning):** Το σύστημα καλείται να ανακαλύψει κρυφές δομές ή μοτίβα σε δεδομένα χωρίς ετικέτες, μέσω τεχνικών όπως η συσταδοποίηση (clustering) ή η μείωση διαστάσεων (dimensionality reduction)[cite: 2].
- **Ενισχυτική Μάθηση (Reinforcement Learning - RL):** Σε αυτή τη μορφή μάθησης, ένας πράκτορας (agent) αλληλεπιδρά με ένα περιβάλλον και μαθαίνει να

λαμβάνει αποφάσεις, με σκοπό τη μεγιστοποίηση μιας ποσοτικής ανταμοιβής μέσω διαδικασιών δοκιμής και λάθους[cite: 2].

3.2. Νευρωνικά Δίκτυα και Βαθιά Μάθηση

Η βαθιά μάθηση (Deep Learning) αποτελεί υποκλάδο της μηχανικής μάθησης, ο οποίος βασίζεται σε Τεχνητά Νευρωνικά Δίκτυα (Artificial Neural Networks - ANNs) με πολλαπλά κρυφά στρώματα[cite: 2]. Τα δίκτυα αυτά προσομοιώνουν τη λειτουργία των βιολογικών νευρώνων και επιτρέπουν την εξαγωγή χαρακτηριστικών υψηλού επιπέδου.

Η έξοδος a ενός τυπικού τεχνητού νευρώνα υπολογίζεται από τη σχέση:

$$a = f \left(\sum_{i=1}^N w_i x_i + b \right) \quad (3.1)$$

όπου x_i αποτελούν τις εισόδους, w_i τα αντίστοιχα βάρη, b τη μεροληψία (bias) και $f(\cdot)$ τη μη γραμμική συνάρτηση ενεργοποίησης[cite: 2].

3.2.1. Συναρτήσεις Ενεργοποίησης

Οι συναρτήσεις ενεργοποίησης εισάγουν τη μη γραμμικότητα στα νευρωνικά δίκτυα, επιτρέποντάς τους να επιλύουν σύνθετα προβλήματα[cite: 2]. Βασικές συναρτήσεις είναι:

- **Λογιστική / Σιγμοειδής (Sigmoid):** $\sigma(x) = \frac{1}{1+e^{-x}}$, η οποία συμπιέζει τις τιμές στο εύρος $(0, 1)$ [cite: 2].
- **Υπερβολική Εφαπτομένη (Tanh):** $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$, η οποία συμπιέζει τις τιμές στο εύρος $(-1, 1)$ [cite: 2]. Έχει το πλεονέκτημα ότι είναι κεντραρισμένη στο μηδέν[cite: 2]. Στα δίκτυα πολιτικής (policy networks) του PPO, η συνάρτηση Tanh είναι εξαιρετικά κρίσιμη για συνεχή ελέγχο, καθώς διατηρεί τις τιμές φραγμένες, αποτρέποντας την εκρηκτική αύξηση της διακύμανσης και των λογαριθμικών πιθανοτήτων (log probabilities), πρόβλημα που εμφανίζεται συχνά κατά τη χρήση της ReLU[cite: 1].
- **Διορθωμένη Γραμμική Συνάρτηση (ReLU):** $\text{ReLU}(x) = \max(0, x)$. Είναι ευρέως διαδεδομένη καθώς μειώνει δραστικά το πρόβλημα της εξασθένησης της παραγώγου (vanishing gradient)[cite: 2].
- **Σιγμοειδής Γραμμική Συνάρτηση (SiLU / Swish):** $\text{SiLU}(x) = x \cdot \sigma(x)$. Αποτελεί μια ομαλή, μη μονότονη συνάρτηση που αποδίδει εξαιρετικά σε βαθιές αρχιτεκτονικές, συνδυάζοντας τη γραμμικότητα της ReLU με τη διαβαθμισμένη ομαλότητα της Sigmoid[cite: 1, 2].

3.2.2. Βελτιστοποίηση και Αλγόριθμος Adam

Κατά την εκπαίδευση (μέσω οπισθοδιάδοσης - backpropagation), χρησιμοποιείται η Κατάβαση Δυναμικού (Gradient Descent)[cite: 2]. Η ενημέρωση των βαρών σε ένα απλό σχήμα ορίζεται ως:

$$\theta_{k+1} = \theta_k - \alpha \nabla_{\theta} J(\pi_{\theta})|_{\theta_k} \quad (3.2)$$

όπου α είναι ο ρυθμός μάθησης (learning rate)[cite: 1].

Ο αλγόριθμος **Adam (Adaptive Moment Estimation)** αποτελεί μια προηγμένη μέθοδο που προσαρμόζει τους ρυθμούς μάθησης ξεχωριστά για κάθε παράμετρο[cite: 1]. Λειτουργεί διατηρώντας εκτιμήσεις της πρώτης και δεύτερης ροπής των κλίσεων[cite: 1]. Συγκεκριμένα, υπολογίζει την "ορμή" (momentum) των κλίσεων[cite: 1]:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (3.3)$$

και έναν κυλιόμενο μέσο όρο των τετραγώνων των κλίσεων[cite: 1]:

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (3.4)$$

όπου $g_t = \nabla_{\theta} L(\theta_t)$. Αφού εφαρμοστεί διόρθωση μεροληψίας (bias correction), οι παράμετροι ενημερώνονται ως εξής[cite: 1]:

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (3.5)$$

Η χρήση του Adam, ή παραλλαγών του όπως ο RAdam, ενδείκνυται στην Ενισχυτική Μάθηση λόγω της αυξημένης σταθερότητας που παρέχει απέναντι στις θορυβώδεις εκτιμήσεις κλίσεων (noisy gradients)[cite: 1, 2].

3.2.3. Δίκτυα Μακράς Βραχύχρονης Μνήμης (LSTM)

Τα παραδοσιακά Αναδρομικά Νευρωνικά Δίκτυα (RNNs) είναι ανεπαρκή για τη διατήρηση πληροφοριών σε μεγάλα χρονικά διαστήματα λόγω του φαινομένου εξασθένησης της κλίσης[cite: 2]. Τα Δίκτυα Μακράς Βραχύχρονης Μνήμης (LSTMs) εισάγουν τη δομή του «κελιού μνήμης» (C_t) το οποίο ελέγχεται από τρεις πύλες (gates)[cite: 2].

Η **Πύλη Λήθης (Forget Gate)** καθορίζει ποιο μέρος της προηγούμενης μνήμης θα διαγραφεί[cite: 2]:

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + b_f) \quad (3.6)$$

Η **Πύλη Εισόδου (Input Gate)** επιλέγει ποια νέα πληροφορία θα προστεθεί[cite: 2]:

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + b_i) \quad (3.7)$$

Η υποψήφια νέα κατάσταση υπολογίζεται μέσω της υπερβολικής εφαπτομένης[cite: 2]:

$$\tilde{C}_t = \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (3.8)$$

Η **Κατάσταση του Κελιού (Cell State)** ανανεώνεται συνδυάζοντας την παλαιά και τη νέα πληροφορία[cite: 2]:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (3.9)$$

Τέλος, η **Πύλη Εξόδου (Output Gate)** καθορίζει την έξοδο (κρυφή κατάσταση) του τρέχοντος βήματος[cite: 2]:

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + b_o) \quad (3.10)$$

$$h_t = o_t \odot \tanh(C_t) \quad (3.11)$$

Τα LSTMs είναι απαραίτητα στις χρηματοοικονομικές αγορές, όπου το περιβάλλον είναι μερικώς παρατηρήσιμο (POMDP) και η λήψη αποφάσεων εξαρτάται από μοτίβα που εκτείνονται σε προηγούμενα χρονικά βήματα[cite: 1].

3.3. Βαθιά Ενισχυτική Μάθηση

Η Ενισχυτική Μάθηση βασίζεται στις Μαρκοβιανές Διαδικασίες Απόφασης (Markov Decision Processes - MDPs), οι οποίες ορίζονται από το σύνολο καταστάσεων S , το σύνολο δράσεων A , τη συνάρτηση μετάβασης $P(s'|s, a)$ και τη συνάρτηση ανταμοιβής $R(s, a)$ [cite: 2].

Στόχος είναι η εύρεση μιας πολιτικής $\pi(a|s)$ που μεγιστοποιεί την αναμενόμενη αθροιστική (προεξοφλημένη) ανταμοιβή. Η Συνάρτηση Αξίας Κατάστασης (State-Value Function) ορίζεται μέσω της εξίσωσης Bellman[cite: 2]:

$$V(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \middle| s_0 = s \right] = \mathbb{E}_\pi [r_t + \gamma V(s_{t+1}) | s_t = s] \quad (3.12)$$

όπου $\gamma \in (0, 1]$ είναι ο συντελεστής προεξοφλησης[cite: 2]. Αντίστοιχα, η Συνάρτηση Αξίας Δράσης-Κατάστασης $Q(s, a)$ εκτιμά την ανταμοιβή επιλογής μιας δράσης a στη δεδομένη κατάσταση s [cite: 2].

3.3.1. Μέθοδοι Δρώντος-Κριτή (Actor-Critic)

Οι σύγχρονες προσεγγίσεις υιοθετούν αρχιτεκτονικές Actor-Critic[cite: 2].

- Ο **Δρών (Actor)** μαθαίνει την παραμετροποιημένη πολιτική $\pi_\theta(a|s)$ και καθορίζει τις δράσεις[cite: 2]. Για συνεχείς χώρους δράσεων, χρησιμοποιείται συχνά μια Γκαουσιανή

κατανομή της οποίας ο μέσος όρος και η διακύμανση εξάγονται από το νευρωνικό δίκτυο[cite: 1].

- Ο **Κριτής (Critic)** μαθαίνει τη συνάρτηση αξίας $V_\phi(s)$ και αξιολογεί τις ενέργειες του Δρώντος, υπολογίζοντας το Πλεονέκτημα (Advantage) $A_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ [cite: 1, 2].

3.3.2. Βελτιστοποίηση Εγγύς Πολιτικής (Proximal Policy Optimization - PPO)

Ο αλγόριθμος PPO επιλύει το πρόβλημα των καταστροφικών μεταβολών στην πολιτική, περιορίζοντας το μέγεθος των ενημερώσεων (policy updates)[cite: 1, 2]. Η μαθηματική διατύπωση του PPO βασίζεται σε μια σύνθετη συνάρτηση κόστους (Composite Loss) η οποία συνενώνει τρεις επιμέρους όρους[cite: 1].

1. Σφάλμα Πολιτικής (Actor / Clipped Surrogate Loss): Έστω $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ ο λόγος πιθανοτήτων. Η απώλεια ορίζεται ως:

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) A_t \right) \right] \quad (3.13)$$

όπου ϵ (συνήθως 0.2) είναι η υπερπαράμετρος που αποτρέπει την πολιτική να μεταβληθεί δραστικά σε ένα μόνο βήμα[cite: 1, 2].

2. Σφάλμα Κριτή (Value / Critic Loss): Η εκπαίδευση του Κριτή απαιτεί την ελαχιστοποίηση του σφάλματος πρόβλεψης. Η απλούστερη μορφή είναι το Μέσο Τετραγωνικό Σφάλμα (Mean Squared Error) μεταξύ των προβλέψεων και των εμπειρικών επιστροφών (returns) R_t [cite: 1]:

$$L^{VF}(\phi) = \frac{1}{2} \mathbb{E}_t [(V_\phi(s_t) - R_t)^2] \quad (3.14)$$

3. Εντροπία (Entropy Bonus): Για να διασφαλιστεί η επαρκής εξερεύνηση (exploration) του χώρου δράσεων, προστίθεται η Shannon εντροπία $H(\pi)$ της κατανομής των ενεργειών[cite: 1]:

$$L^{ENT}(\theta) = \mathbb{E}_t [H(\pi_\theta(\cdot|s_t))] \quad (3.15)$$

Η υψηλότερη εντροπία υποδηλώνει πιο στοχαστική συμπεριφορά[cite: 1].

Η συνολική αντικειμενική συνάρτηση που μεγιστοποιείται σε κάθε επανάληψη του PPO είναι ο γραμμικός συνδυασμός αυτών των όρων[cite: 1, 2]:

$$L^{total} = \mathbb{E}_t [L^{CLIP}(\theta) - c_1 L^{VF}(\phi) + c_2 L^{ENT}(\theta)] \quad (3.16)$$

όπου c_1, c_2 είναι υπερπαράμετροι στάθμισης[cite: 1].

3.4. Επεξεργασία Φυσικής Γλώσσας και Μεγάλα Γλωσσικά Μοντέλα (LLMs)

Εκτός από τα αριθμητικά δεδομένα, τεράστια ποσότητα πληροφορίας κρύβεται στα κείμενα. Τα Μεγάλα Γλωσσικά Μοντέλα (Large Language Models), βασισμένα στην αρχιτεκτονική Transformer και τον Μηχανισμό Προσοχής (Self-Attention), έχουν τη δυνατότητα να επιλύουν πολύπλοκα προβλήματα Επεξεργασίας Φυσικής Γλώσσας (NLP). Μέσα από δισεκατομμύρια παραμέτρους, τα LLMs μπορούν να αναλύσουν τη σημασιολογία οικονομικών άρθρων και αναρτήσεων σε πραγματικό χρόνο, εξάγοντας δείκτες επενδυτικής ψυχολογίας (sentiment).

3.4.1. Αποδοτική Μικρο-προσαρμογή: Low-Rank Adaptation (LoRA)

Η επανεκπαίδευση (full fine-tuning) ενός LLM για εξειδικευμένους σκοπούς, όπως οι χρηματοοικονομικές αγορές, είναι υπολογιστικά απαγορευτική. Η μέθοδος **Low-Rank Adaptation (LoRA)** προσφέρει μια εξαιρετικά αποδοτική εναλλακτική. Η βασική ιδέα είναι το "πάγωμα" των προεκπαιδευμένων παραμέτρων $W_0 \in \mathbb{R}^{d \times k}$ του μοντέλου και η βελτιστοποίηση μόνο πινάκων χαμηλής βαθμίδας.

Συγκεκριμένα, η μεταβολή των βαρών ΔW αναπαρίστανται ως γινόμενο δύο μικρότερων πινάκων A και B :

$$W = W_0 + \Delta W = W_0 + BA \quad (3.17)$$

όπου $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$ και η βαθμίδα (rank) ισχύει ότι $r \ll \min(d, k)$. Κατά τη διάρκεια της εκπαίδευσης (π.χ. σε δεδομένα crypto-sentiment), μόνο οι πίνακες A και B ενημερώνονται, μειώνοντας τις απαιτήσεις μνήμης VRAM σε τεράστιο βαθμό, χωρίς ουσιαστική απώλεια στην ακρίβεια της παραγόμενης γνώσης.

3.5. Χρηματοοικονομικές Συναλλαγές και Αξιολόγηση Μοντέλων

Σύμφωνα με την Υπόθεση Αποτελεσματικής Αγοράς (Efficient Market Hypothesis - EMH), οι τιμές των περιουσιακών στοιχείων αντανακλούν άμεσα όλες τις διαθέσιμες πληροφορίες, καθιστώντας εξαιρετικά δύσκολη τη σταθερή επικράτηση επί της αγοράς[cite: 1]. Παρά την επιρροή της, πολλοί ακαδημαϊκοί και επαγγελματίες θεωρούν ότι οι αγορές παρουσιάζουν αναποτελεσματικότητες λόγω ψυχολογικών ή συμπεριφορικών παραγόντων[cite: 1].

3.5.1. Χρηματοοικονομικά Δεδομένα και Ανάλυση

Στην πράξη, η ανάλυση βασίζεται σε δομημένα δεδομένα τύπου OHLCV (Open, High, Low, Close, Volume) που συγκροτούν τα διαγράμματα κεριών (candlesticks)[cite: 2]. Η ενσωμάτωση του συναισθήματος (sentiment) που παράγεται από LLMs προσθέτει μια επιπλέον διάσταση σε αυτά τα δεδομένα, ποσοτικοποιώντας τον φόβο ή την απληστία της αγοράς σε κάθε χρονικό βήμα.

3.5.2. Αξιολόγηση σε Χρονοσειρές: Combinatorial Purged Cross-Validation (CPCV)

Η αξιολόγηση ενός πράκτορα DRL σε χρηματοοικονομικά δεδομένα είναι επιρρεπής στην υπερπροσαρμογή (backtest overfitting). Το κοινό Cross-Validation συχνά αποτυγχάνει λόγω της διαρροής μελλοντικής πληροφορίας (look-ahead bias)[cite: 1].

Η μέθοδος **Combinatorial Purged Cross-Validation (CPCV)** αποτελεί την κορυφαία προσέγγιση για χρονοσειρές. Σε αντίθεση με την τυπική K-Fold επικύρωση, η CPCV:

1. Χωρίζει το σύνολο δεδομένων σε διακριτές χρονικές ομάδες (groups).
2. Δοκιμάζει κάθε δυνατό συνδυασμό ομάδων ως σύνολο δοκιμής (test set).
3. Εφαρμόζει τον «Καθαρισμό» (*Purging*): Αφαιρεί (purges) παρατηρήσεις από το training set οι οποίες βρίσκονται χρονικά πολύ κοντά στις ομάδες του test set[cite: 1].

Με αυτόν τον τρόπο διασφαλίζεται ότι ο πράκτορας PPO-LSTM εκπαιδεύεται χωρίς καμία μνήμη ή διαρροή της μελλοντικής συμπεριφοράς της αγοράς, οδηγώντας σε ρεαλιστικές, αυστηρές και αμερόληπτες επιλογές υπερπαραμέτρων.

4

Experimental Evaluation

5

Conclusions & Future Work

References



Appendix
